

Ingeniería de características: desarrollo matemático, contraste de técnicas y servicios de AWS donde se aplican

Desarrollo del Capítulo 3 de la guía oficial MLA-C01

Septiembre de 2026

Índice

1. Marco general	2
1.1. Datos, características y transformaciones ajustadas	2
2. Limpieza de datos	4
2.1. Valores faltantes	4
2.2. Valores atípicos	6
2.3. Deduplicación	9
3. Selección y extracción de características	9
3.1. Métodos de filtro	9
3.2. Redundancia, colinealidad y fuga del objetivo	11
3.3. Extracción lineal: análisis de componentes principales	11
4. Escalado de características numéricas	12
4.1. Por qué importa la escala	12
4.2. La familia de escaladores afines	14
5. Transformaciones no lineales	15
5.1. Asimetría por cuantiles y transformaciones cóncavas	16
5.2. La escalera de potencias y la familia de Box–Cox	17
5.3. Yeo–Johnson: ceros y negativos	19
5.4. Estabilización de la varianza	19
5.5. Logaritmo y raíces: casos particulares y contraste	20
6. Discretización	21
7. Codificación de variables categóricas	22
7.1. Codificación por etiquetas u ordinal	23
7.2. Codificación one-hot	23
7.3. Codificación binaria	24
7.4. Hashing de características	25
7.5. Contraste de las codificaciones	28

8. Series de tiempo	28
8.1. Descomposición de la fecha y codificación cíclica	28
8.2. Rezagos y autocorrelación	30
8.3. Ventanas móviles	30
9. Imágenes	31
9.1. Normalización de píxeles	31
9.2. Características diseñadas a mano: bordes	31
9.3. Convolución y redes convolucionales	32
10. Texto	33
10.1. Tokenización y bolsa de palabras	33
10.2. Palabras vacías, ponderación TF-IDF y reducción a raíces	33
10.3. N-gramas	34
10.4. Embeddings de palabras	34
10.5. Tokenización en modelos fundacionales	36
11. Desbalance de clases	36
11.1. Ponderación y remuestreo	37
11.2. SMOTE	38
11.3. Aumento de datos	38
11.4. Métricas de sesgo previas al entrenamiento	39
12. División de datos y fuga	39
13. Servicios de AWS donde se aplican las técnicas	40

1. Marco general

Este texto desarrolla con rigor las técnicas de transformación de datos e ingeniería de características que presenta el Capítulo 3 de la guía de estudio del examen AWS Certified Machine Learning Engineer – Associate: limpieza (valores faltantes, atípicos, duplicados), selección y extracción de características, escalado, transformaciones no lineales, discretización, codificación de variables categóricas, características de series de tiempo, de imágenes y de texto, tratamiento del desbalance de clases y división de datos. Para cada técnica se da su formulación matemática, se demuestran las propiedades que la guía afirma (y algunas que da por sentadas), se señalan sus límites mediante contraejemplos y se contrasta con las técnicas que compiten con ella. La última sección enumera los servicios de AWS en los que se aplica cada técnica, con el mismo reparto que hace la guía.

El nivel supuesto es el de un lector con formación en probabilidad y estadística matemática (esperanza, varianza, cuantiles, estimación por máxima verosimilitud, regresión lineal por mínimos cuadrados) y álgebra lineal (valores propios, rango, proyecciones). No se usa teoría de la medida.

1.1. Datos, características y transformaciones ajustadas

El problema que motiva toda la disciplina es el siguiente. Un algoritmo de aprendizaje supervisado recibe pares (x_i, y_i) con $x_i \in \mathbb{R}^p$ y busca una función f tal que $f(x_i)$ aproxime a y_i . Pero los datos crudos rara vez son vectores de $\mathbb{R}^p$ adecuados: contienen cadenas de texto, fechas, imágenes, huecos, escalas incomparables y errores. La ingeniería de características es la construcción de una aplicación

que lleva cada registro crudo a un vector numérico con el que el algoritmo aprende mejor. Conviene fijar la notación con la que se hablará de ella.

Definición 1.1 (Registro, característica, matriz de diseño). Sea $\mathcal{Z}$ el conjunto de registros crudos posibles (filas de una tabla con columnas de tipos mixtos, imágenes, documentos). Un *conjunto de datos* es una sucesión finita $\mathcal{D} = ((z_1, y_1), \dots, (z_n, y_n))$ con $z_i \in \mathcal{Z}$ y y_i en un conjunto de etiquetas $\mathcal{Y}$ (por ejemplo $\mathcal{Y} = \mathbb{R}$ en regresión o $\mathcal{Y} = \{0, 1\}$ en clasificación binaria). Una *característica* es una función $\phi_j : \mathcal{Z} \rightarrow \mathbb{R}$; un *mapa de características* es $\phi = (\phi_1, \dots, \phi_p) : \mathcal{Z} \rightarrow \mathbb{R}^p$. La *matriz de diseño* es $X \in \mathbb{R}^{n \times p}$ con entradas $X_{ij} = \phi_j(z_i)$; su fila i se denota $x_i^\top$ y su columna j , $x_{.j}$.

En vocabulario estadístico, las características son las covariables o predictores y y es la variable respuesta. La definición separa deliberadamente el registro z de su representación $\phi(z)$: la ingeniería de características consiste precisamente en elegir ϕ . Dos ejemplos del texto original muestran el alcance. Si z es una fila con una columna de fecha, la característica “día de la semana” es $\phi(z) \in \{0, \dots, 6\}$, que no está escrita en la tabla pero se calcula de ella. Si z es una imagen, $\phi(z)$ puede ser la intensidad de cada píxel (con p del orden de 10^5) o un vector corto calculado por una red neuronal (Sección 9).

Casi todas las transformaciones de este texto dependen de parámetros que se estiman con los datos: la media y la desviación estándar de un escalador, los cuartiles del método IQR, el vocabulario de un codificador, la λ de Box–Cox, los ejes de un PCA. Esta dependencia es la fuente del error más grave de la ingeniería de características, la fuga de datos, y por eso se formaliza desde el principio.

Definición 1.2 (Transformación ajustada). Una *transformación ajustada* es un par $(\hat{\theta}, T)$ donde $\hat{\theta}$ es una función que asigna a cada conjunto de datos $\mathcal{D}$ un parámetro $\hat{\theta}(\mathcal{D})$ en un espacio Θ (la etapa **fit**), y $T : \Theta \times \mathbb{R}^p \rightarrow \mathbb{R}^q$ aplica la transformación a un vector con un parámetro dado (la etapa **transform**). Escribimos $T_\theta(x) = T(\theta, x)$.

Por ejemplo, la estandarización corresponde a $\hat{\theta}(\mathcal{D}) = (\bar{x}, s)$ (media y desviación estándar muestrales de la columna) y $T_{(\mu, \sigma)}(x) = (x - \mu)/\sigma$. La separación entre $\hat{\theta}$ y T es exactamente la separación entre los métodos **fit** y **transform** de scikit-learn que describe la guía.

El uso correcto de una transformación ajustada se deduce de cómo se usará el modelo. En producción, el modelo recibe un registro nuevo z_{new} que no existía cuando se entrenó; la transformación que se le aplica solo puede depender de los datos de entrenamiento. Si la evaluación ha de imitar la producción, lo mismo debe valer para los datos de prueba.

Definición 1.3 (Fuga de datos por preprocesamiento). Sea $\mathcal{D} = \mathcal{D}_{\text{tr}} \cup \mathcal{D}_{\text{te}}$ una partición en entrenamiento y prueba. Se dice que un procedimiento de evaluación tiene *fuga de datos por preprocesamiento* si la transformación aplicada a los registros de $\mathcal{D}_{\text{te}}$ es $T_{\hat{\theta}(\mathcal{D}')}$ con $\mathcal{D}' \cap \mathcal{D}_{\text{te}} \neq \emptyset$, es decir, si el parámetro ajustado usó algún registro de prueba. El procedimiento correcto usa $T_{\hat{\theta}(\mathcal{D}_{\text{tr}})}$ tanto para $\mathcal{D}_{\text{tr}}$ como para $\mathcal{D}_{\text{te}}$.

La condición es precisa: no basta con que el modelo no “vea” los datos de prueba, tampoco deben verlos los parámetros de la transformación. El ejemplo siguiente muestra que la fuga cambia efectivamente lo que se evalúa.

Ejemplo 1.4 (La media ajustada contiene información de prueba). Sea $\mathcal{D}_{\text{tr}} = \{x_1, \dots, x_m\}$ y $\mathcal{D}_{\text{te}} = \{x_{m+1}, \dots, x_n\}$ en una sola columna, y sea $\bar{x}_{\text{tr}} = \frac{1}{m} \sum_{i \leq m} x_i$, $\bar{x}_{\text{te}} = \frac{1}{n-m} \sum_{i > m} x_i$. La media de todos los datos es

$$\bar{x} = \frac{m}{n} \bar{x}_{\text{tr}} + \frac{n-m}{n} \bar{x}_{\text{te}}, \quad (1)$$

lo que se obtiene separando la suma $\sum_{i=1}^n x_i = m\bar{x}_{\text{tr}} + (n - m)\bar{x}_{\text{te}}$ y dividiendo entre n . Si se centra con $\bar{x}$, el valor transformado de un punto de entrenamiento es $x_i - \bar{x}$, que por (1) depende de $\bar{x}_{\text{te}}$: al variar un solo dato de prueba en δ , cada dato de entrenamiento transformado cambia en $-\delta/n$. El modelo entrenado sobre esos valores es, por tanto, función de los datos de prueba, y la evaluación deja de medir el desempeño sobre datos no vistos. En este ejemplo el efecto es pequeño (orden $1/n$); en transformaciones con muchos parámetros, como el vocabulario de un codificador o el sobremuestreo sintético (Sección 11), puede ser grande.

La regla práctica que la guía enuncia sin justificar, “normaliza o estandariza siempre después de dividir”, es la Definición 1.3 aplicada a los escaladores. La misma regla rige para la media de imputación, los límites del IQR, el vocabulario de un codificador, las componentes de un PCA y el sobremuestreo. A lo largo del texto se señalará qué parámetros ajusta cada técnica.

2. Limpieza de datos

2.1. Valores faltantes

Motivación. Casi todos los algoritmos clásicos (regresión lineal y logística, máquinas de vectores de soporte, k vecinos) están definidos sobre vectores de $\mathbb{R}^p$ completos: la expresión $\beta^\top x$ no tiene sentido si falta una coordenada. Descartar las filas incompletas es la solución más simple, pero con p columnas en las que cada entrada falta de manera independiente con probabilidad r , la probabilidad de que una fila esté completa es $(1 - r)^p$; con $r = 0.02$ y $p = 50$ esto da $0.98^{50} \approx 0.36$, así que se perdería cerca de dos tercios del conjunto de datos por huecos que afectan al 2% de las celdas. Esta pérdida motivó la imputación. El análisis de cuándo la imputación es inocua requiere precisar *por qué* falta el dato, que es lo que formalizó Rubin (1976).

Definición 2.1 (Mecanismos de falta). Sea $X = (X_{\text{obs}}, X_{\text{mis}})$ el vector completo de un registro, separado en la parte observada y la faltante, y sea R el vector de indicadores de respuesta ($R_j = 1$ si la coordenada j se observó). El mecanismo de falta es:

- (a) *completamente al azar* (MCAR) si R es independiente de X ;
- (b) *al azar* (MAR) si la distribución de R condicionada a X depende solo de X_{obs} ;
- (c) *no al azar* (MNAR) en cualquier otro caso, es decir, cuando la probabilidad de faltar depende del propio valor no observado.

La guía describe el caso de “pocos valores faltantes distribuidos aleatoriamente” por una falla de ingesta; eso es MCAR. Un ejemplo de MNAR es el ingreso declarado, cuando los ingresos altos se declaran con menos frecuencia.

Proposición 2.2 (La media observada bajo MCAR y MNAR). Sean $X_1, \dots, X_n$ i.i.d. con media μ finita y $R_1, \dots, R_n$ sus indicadores de respuesta, y sea $M = \sum_i R_i$.

- (i) Si el mecanismo es MCAR, con $(R_1, \dots, R_n)$ independiente de $(X_1, \dots, X_n)$, entonces $\mathbb{E}[\bar{X}_{\text{obs}} \mid R_1, \dots, R_n] = \mu$ en el suceso $M \geq 1$, donde $\bar{X}_{\text{obs}} = M^{-1} \sum_i R_i X_i$.
- (ii) Si $X_i \sim \text{Exp}(1)$ y cada valor se observa si y solo si $X_i \leq c$ (MNAR), entonces $\mathbb{E}[X_i \mid R_i = 1] = 1 - \frac{ce^{-c}}{1 - e^{-c}} < 1 = \mu$.

Demostración. (i) Condicionando a $R = (R_1, \dots, R_n)$ con $M \geq 1$, M y los R_i son constantes, así que por linealidad $\mathbb{E}[\bar{X}_{\text{obs}} \mid R] = M^{-1} \sum_i R_i \mathbb{E}[X_i \mid R]$. Por la independencia entre R y X , la distribución condicional de X_i dado R es la marginal, de modo que $\mathbb{E}[X_i \mid R] = \mu$. Por tanto $\mathbb{E}[\bar{X}_{\text{obs}} \mid R] = M^{-1} \mu \sum_i R_i = \mu$.

(ii) El suceso $R_i = 1$ es $\{X_i \leq c\}$, con probabilidad $\int_0^c e^{-x} dx = 1 - e^{-c}$. Integrando por partes con $u = x$, $dv = e^{-x} dx$,

$$\int_0^c x e^{-x} dx = [-x e^{-x}]_0^c + \int_0^c e^{-x} dx = -c e^{-c} + 1 - e^{-c}.$$

Dividiendo entre $\mathbb{P}(X_i \leq c)$ se obtiene $\mathbb{E}[X_i \mid X_i \leq c] = \frac{1 - e^{-c} - c e^{-c}}{1 - e^{-c}} = 1 - \frac{c e^{-c}}{1 - e^{-c}}$, y el sustraendo es positivo para $c > 0$. $\square$

Con $c = 2$ la media condicionada vale $1 - 2e^{-2}/(1 - e^{-2}) \approx 0.687$: imputar con la media observada subestima la media real en un 31 %, por grande que sea la muestra. La imputación simple, por tanto, solo es defendible bajo MCAR (o bajo MAR si se imputa condicionando a lo observado). La guía también distingue entre imputar con la media, la mediana o la moda. Las tres son el mejor valor constante bajo pérdidas distintas.

Proposición 2.3 (Media, mediana y moda como constantes óptimas). *Sean $x_1, \dots, x_m$ los valores observados de una característica.*

(i) $\sum_i (x_i - c)^2$ se minimiza en $c = \bar{x}$, y solo ahí.

(ii) $\sum_i |x_i - c|$ se minimiza en cualquier mediana muestral.

(iii) Si los valores pertenecen a un conjunto finito, $\sum_i \mathbf{1}[x_i \neq c]$ se minimiza en cualquier moda.

Demostración. (i) Sumando y restando $\bar{x}$, $\sum_i (x_i - c)^2 = \sum_i (x_i - \bar{x})^2 + 2(\bar{x} - c) \sum_i (x_i - \bar{x}) + m(\bar{x} - c)^2$. El término cruzado es nulo porque $\sum_i (x_i - \bar{x}) = \sum_i x_i - m\bar{x} = 0$. Queda $\sum_i (x_i - \bar{x})^2 + m(\bar{x} - c)^2$, que es mínimo si y solo si $c = \bar{x}$.

(ii) La función $g(c) = \sum_i |x_i - c|$ es continua y lineal a trozos. En un punto c distinto de todos los x_i , su derivada es $\#\{i : x_i < c\} - \#\{i : x_i > c\}$, porque cada término $|x_i - c|$ tiene derivada $+1$ si $x_i < c$ y -1 si $x_i > c$. Esa derivada es ≤ 0 mientras a lo sumo la mitad de los datos quede a la izquierda de c y ≥ 0 en cuanto a lo sumo la mitad quede a la derecha. Luego g es no creciente a la izquierda de cualquier mediana y no decreciente a su derecha, y el mínimo se alcanza en las medianas.

(iii) $\sum_i \mathbf{1}[x_i \neq c] = m - \#\{i : x_i = c\}$, que es mínimo cuando la frecuencia de c es máxima, es decir, en una moda. $\square$

La proposición justifica la regla de la guía: la media es natural cuando interesa el error cuadrático y la distribución es simétrica (en cuyo caso media y mediana coinciden en la población); con asimetría o atípicos, la mediana es preferible porque, como se verá en la Proposición 2.10, no la arrastra un solo valor extremo; para una característica categórica solo tiene sentido la moda, porque no hay suma ni orden. La imputación tiene además un costo sobre la dispersión que la guía no menciona.

Proposición 2.4 (La imputación por la media reduce la varianza). *Sea una columna con n registros, de los cuales m están observados ($2 \leq m < n$), con media $\bar{x}_{\text{obs}}$ y varianza muestral $s_{\text{obs}}^2 = \frac{1}{m-1} \sum_{\text{obs}} (x_i - \bar{x}_{\text{obs}})^2$. Si los $n - m$ huecos se rellenan con $\bar{x}_{\text{obs}}$, la columna completada tiene media $\bar{x}_{\text{obs}}$ y varianza*

$$s_{\text{imp}}^2 = \frac{m-1}{n-1} s_{\text{obs}}^2 < s_{\text{obs}}^2 \quad \text{si } s_{\text{obs}}^2 > 0.$$

Demostración. La suma de la columna completada es $m\bar{x}_{\text{obs}} + (n - m)\bar{x}_{\text{obs}} = n\bar{x}_{\text{obs}}$, así que su media es $\bar{x}_{\text{obs}}$. En la suma de cuadrados respecto de esa media, cada valor imputado contribuye $(\bar{x}_{\text{obs}} - \bar{x}_{\text{obs}})^2 = 0$, por lo que la suma total es $\sum_{\text{obs}} (x_i - \bar{x}_{\text{obs}})^2 = (m - 1)s_{\text{obs}}^2$. Dividiendo entre $n - 1$ se obtiene la fórmula, y $\frac{m-1}{n-1} < 1$ porque $m < n$. $\square$

Con un 30 % de huecos ($m = 0.7n$) la varianza se reduce aproximadamente al 70 %. Un modelo que use esa columna ve una característica artificialmente concentrada, y los valores imputados forman una masa puntual en $\bar{x}_{\text{obs}}$ que no existe en la población. Por eso la guía sugiere acompañar la imputación con un indicador $x^{\text{mis}} = \mathbf{1}[\text{valor faltante}]$: este indicador permite al modelo tratar distinto a los registros imputados y, en situación MNAR, recoge la información que el hecho de faltar contiene sobre la respuesta. La media y la mediana de imputación son parámetros ajustados en el sentido de la Definición 1.2 y deben calcularse solo con $\mathcal{D}_{\text{tr}}$.

Contraste de las tres estrategias. Eliminar filas conserva la distribución de las filas completas pero pierde datos (el factor $(1 - r)^p$) y sesga bajo MNAR; eliminar una columna solo es razonable si concentra los huecos; imputar conserva todas las filas pero reduce la varianza (Proposición 2.4) y sesga bajo MNAR (Proposición 2.2). Recolectar de nuevo es la única opción que corrige un mecanismo MNAR, y su costo es el que la guía pide sopesar. Algunas implementaciones de *gradient boosting* evitan la imputación aprendiendo, en cada corte, hacia qué rama enviar los faltantes.

2.2. Valores atípicos

Motivación. Desde Gauss, el modelo de referencia para los errores de medición es la distribución normal, y bajo ese modelo un valor a más de tres desviaciones estándar de la media es muy improbable. De ahí proviene la regla de las tres sigmas que cita la guía. En el siglo XX se observó que esta regla falla precisamente cuando más se la necesita: los atípicos inflan la media y la desviación estándar con las que se los busca. Tukey (1977) propuso reglas basadas en cuartiles, y la teoría de la robustez de Huber y Hampel dio una medida precisa de cuánto puede un estimador resistir la contaminación. Esta subsección reconstruye ese desarrollo.

Definición 2.5 (Puntuación Z). Dada una muestra $x_1, \dots, x_n$ con media $\bar{x}$ y desviación estándar $s > 0$, la *puntuación Z* de x_i es $z_i = (x_i - \bar{x})/s$. La *regla de las tres sigmas* declara atípico a x_i si $|z_i| > 3$.

Hay dos convenciones para s : la *poblacional* $s_0^2 = \frac{1}{n} \sum_i (x_i - \bar{x})^2$ (la que usa `scipy.stats.zscore` por defecto) y la *muestral* $s_1^2 = \frac{1}{n-1} \sum_i (x_i - \bar{x})^2$. La justificación probabilística de la regla, bajo normalidad, es que $\mathbb{P}(|Z| \leq 3) = 0.9973$ para $Z \sim N(0, 1)$, así que solo un 0.27 % de las observaciones de una normal quedaría marcada (la guía redondea a 0.3 %). Sin normalidad la cota disponible es mucho más débil.

Proposición 2.6 (Desigualdad de Chebyshev). Si X tiene media μ y varianza $\sigma^2 \in (0, \infty)$, entonces para todo $k > 0$, $\mathbb{P}(|X - \mu| \geq k\sigma) \leq 1/k^2$.

Demostración. Sea $A = \{|X - \mu| \geq k\sigma\}$. En A se cumple $(X - \mu)^2 \geq k^2\sigma^2$, y fuera de A se cumple $(X - \mu)^2 \geq 0$. Por tanto $(X - \mu)^2 \geq k^2\sigma^2 \mathbf{1}[A]$ en todo punto. Tomando esperanzas, $\sigma^2 \geq k^2\sigma^2\mathbb{P}(A)$, y dividiendo entre $k^2\sigma^2$ se obtiene la cota. $\square$

Para $k = 3$ la cota es $1/9 \approx 11\%$, cuarenta veces el 0.27 % normal. La cota se alcanza: la variable que vale ± 3 con probabilidad $1/18$ cada uno y 0 con probabilidad $8/9$ tiene media 0, varianza $2 \cdot 9/18 = 1$ y $\mathbb{P}(|X| \geq 3) = 1/9$. Así, sin un supuesto de forma, “tres desviaciones” no fija ninguna proporción de atípicos. La guía muestra además que, en su ejemplo de diez puntos, la regla no detecta el punto [25, 23]. Hay una razón puramente aritmética.

Proposición 2.7 (Cota de Samuelson–Shiffler). Sea $n \geq 2$ y $x_1, \dots, x_n$ con $s > 0$. Entonces, para todo i ,

$$|z_i| \leq \sqrt{n-1} \quad \text{si } s = s_0, \quad |z_i| \leq \frac{n-1}{\sqrt{n}} \quad \text{si } s = s_1.$$

Demostración. Sin pérdida de generalidad $i = 1$. Sea $d_j = x_j - \bar{x}$. Como $\sum_j d_j = 0$, se tiene $d_1 = -\sum_{j \geq 2} d_j$. Por la desigualdad de Cauchy–Schwarz aplicada a los vectores $(1, \dots, 1)$ y $(d_2, \dots, d_n)$ de $\mathbb{R}^{n-1}$,

$$d_1^2 = \left(\sum_{j \geq 2} d_j \right)^2 \leq (n-1) \sum_{j \geq 2} d_j^2.$$

Entonces $\sum_{j=1}^n d_j^2 = d_1^2 + \sum_{j \geq 2} d_j^2 \geq d_1^2 + \frac{d_1^2}{n-1} = \frac{n}{n-1} d_1^2$. Con $s = s_0$ el miembro izquierdo es ns_0^2 , de donde $d_1^2 \leq (n-1)s_0^2$ y $|z_1| \leq \sqrt{n-1}$. Con $s = s_1$ el miembro izquierdo es $(n-1)s_1^2$, de donde $d_1^2 \leq \frac{(n-1)^2}{n} s_1^2$ y $|z_1| \leq (n-1)/\sqrt{n}$. $\square$

La igualdad en Cauchy–Schwarz exige $d_2 = \dots = d_n$, es decir, que todos los demás puntos coincidan. Con $n = 10$ y la convención poblacional la cota es $\sqrt{9} = 3$: ningún punto puede tener $|z| > 3$, cualquiera que sea su valor, y el valor 3 solo se alcanza si los otros nueve son idénticos. (Con la convención muestral la cota es $9/\sqrt{10} \approx 2.85$.) La regla de las tres sigmas es, por tanto, vacía para $n \leq 10$. La segunda razón de su fallo es el *enmascaramiento*.

Ejemplo 2.8 (Enmascaramiento en el ejemplo de la guía). Para la segunda característica del ejemplo de la guía, $y = (11, 12, 12.5, 8, 8.5, 7.5, 5, 4.7, 6, 23)$, se tiene $\bar{y} = 9.82$ y $s_0 = 5.114$, así que el punto 23 tiene $z = (23 - 9.82)/5.114 = 2.58$. Si en cambio se calculan la media y la desviación estándar muestral de los otros nueve puntos ($\bar{y}_{(-10)} = 8.356$, $s_{1,(-10)} = 2.926$), la distancia estandarizada de 23 es $(23 - 8.356)/2.926 \approx 5.0$. El atípico infla la s con la que se lo mide y se oculta: la suma de cuadrados pasa de $8 \cdot 2.926^2 \approx 68.5$ sin él a $10 \cdot 5.114^2 \approx 261.5$ con él, y casi tres cuartas partes de la dispersión total provienen de ese único punto.

La herramienta que mide esta fragilidad es el punto de ruptura.

Definición 2.9 (Punto de ruptura finito). Sea T un estimador que asigna un número real a cada muestra de tamaño n . El *punto de ruptura finito* de T en la muestra x es la menor fracción k/n tal que, reemplazando k de los n valores por valores arbitrarios, $|T|$ puede hacerse tan grande como se quiera.

La definición captura la propiedad deseada (“unos pocos datos corruptos no deben poder llevar el estimador a cualquier parte”) de forma cuantitativa, y permite comparar estimadores de posición y de escala.

Proposición 2.10 (Punto de ruptura de media, mediana y cuartiles). Para una muestra de tamaño n : (i) la media y la desviación estándar tienen punto de ruptura $1/n$; (ii) la mediana tiene punto de ruptura $\lceil n/2 \rceil/n$, que tiende a $1/2$; (iii) los cuartiles Q_1, Q_3 y el IQR = $Q_3 - Q_1$ tienen punto de ruptura del orden de $1/4$.

Demostración. (i) Reemplazando x_1 por t , la media es $(t + \sum_{j \geq 2} x_j)/n$, que tiende a ∞ con t ; un solo valor basta. Para la desviación estándar, $ns_0^2 \geq (t - \bar{x})^2$ y $t - \bar{x} = \frac{n-1}{n}t - \frac{1}{n} \sum_{j \geq 2} x_j \rightarrow \infty$.

(ii) Si se reemplazan $k < n/2$ valores, más de la mitad de los datos siguen siendo originales, luego la mediana queda entre el mínimo y el máximo de los datos originales y está acotada. Si se reemplazan $k \geq \lceil n/2 \rceil$ valores por un mismo t grande, al menos la mitad de la muestra vale t y la mediana es $\geq t$ (o el promedio de t con un valor acotado, si n es par y $k = n/2$), que tiende a ∞ .

(iii) El mismo argumento, aplicado al cuantil de orden $1/4$ o $3/4$: mientras menos de aproximadamente un cuarto de los datos se reemplace, en cada cola quedan datos originales suficientes para que el cuantil quede entre valores originales; al reemplazar un cuarto o más en la cola correspondiente, el cuantil puede llevarse a infinito, y con él el IQR. $\square$

La regla de Tukey sustituye la media y la desviación estándar por cuartiles.

Definición 2.11 (Regla del rango intercuartílico). Sean Q_1 y Q_3 los cuartiles muestrales y $\text{IQR} = Q_3 - Q_1$. Un valor x es atípico según la *regla del IQR* (o vallas de Tukey) si $x < Q_1 - 1.5 \text{ IQR}$ o $x > Q_3 + 1.5 \text{ IQR}$.

La constante 1.5 no es arbitraria: fija qué fracción de una normal se marcaría, que resulta comparable a la de la regla de las tres sigmas.

Proposición 2.12 (Vallas de Tukey bajo normalidad). Si $X \sim N(\mu, \sigma^2)$, las vallas poblacionales son $\mu \pm 4z_{0.75}\sigma \approx \mu \pm 2.698\sigma$, donde $z_{0.75} \approx 0.6745$ es el cuantil 0.75 de la normal estándar, y la probabilidad de caer fuera de ellas es aproximadamente 0.70 %.

Demostración. Por simetría de la normal, $Q_1 = \mu - z_{0.75}\sigma$ y $Q_3 = \mu + z_{0.75}\sigma$, luego $\text{IQR} = 2z_{0.75}\sigma$. La valla superior es $Q_3 + 1.5 \text{ IQR} = \mu + z_{0.75}\sigma + 3z_{0.75}\sigma = \mu + 4z_{0.75}\sigma$, y la inferior es simétrica. Con $z_{0.75} = 0.6745$ resulta $4z_{0.75} = 2.698$, y $\mathbb{P}(|Z| > 2.698) = 2(1 - \Phi(2.698)) \approx 0.0070$. $\square$

Así, bajo normalidad las dos reglas son comparables (0.27 % frente a 0.70 %), pero la del IQR hereda el punto de ruptura de los cuartiles (Proposición 2.10) en lugar del de la media.

Ejemplo 2.13 (Regla del IQR en el ejemplo de la guía). Con la interpolación lineal de pandas, para y se obtiene $Q_1 = 6.375$, $Q_3 = 11.75$, $\text{IQR} = 5.375$ y valla superior $11.75 + 1.5 \cdot 5.375 = 19.8125$. El valor 23 la supera y se marca. Para $x = (4, 3.8, 4.5, 8, 9, 9.5, 13, 14, 13.7, 25)$ se obtiene $Q_1 = 5.375$, $Q_3 = 13.525$, $\text{IQR} = 8.15$ y valla superior 25.75, así que $x = 25$ no se marca. La fila [25, 23] se marca porque el código de la guía usa `.any(axis=1)`: basta que una coordenada caiga fuera.

Contraste Z frente a IQR. La puntuación Z usa estimadores con punto de ruptura $1/n$, está acotada por $\sqrt{n-1}$ (Proposición 2.7), sufre enmascaramiento (Ejemplo 2.8) y su calibración (0.27 %) solo vale bajo normalidad. La regla del IQR usa estimadores con punto de ruptura cercano a $1/4$, no depende de la media y es aplicable con asimetría; su desventaja es que, bajo normalidad y con muestras grandes, marca más puntos legítimos (0.70 %) y que, en distribuciones de colas pesadas (lognormal, Pareto), marca como atípicos valores que son parte natural de la cola. Ambas son reglas univariantes: un punto puede ser atípico solo en la combinación de dos coordenadas y pasar ambas reglas. Tanto la media y s como los cuartiles son parámetros ajustados y deben calcularse con $\mathcal{D}_{\text{tr}}$.

Tratamiento. La guía enumera tres tratamientos: eliminar, imputar y transformar con logaritmo. Eliminar es correcto si el atípico es un error; si es un valor natural (una compra legítima de 150 000 en un modelo de fraude) eliminarlo quita justamente la información más valiosa. Imputar hereda los problemas de la Proposición 2.4. La transformación logarítmica se aplica a toda la columna, no solo al atípico (si se aplicara solo al punto, la columna mezclaría dos escalas), y su efecto se estudia en la Sección 5: en el ejemplo de la guía la puntuación Z de 23 pasa de 2.58 a 2.11 tras aplicar $\log_{10}$ a la columna, lo que se verifica calculando la media (0.9436) y la desviación estándar poblacional (0.1984) de los logaritmos: $(\log_{10} 23 - 0.9436)/0.1984 = (1.3617 - 0.9436)/0.1984 \approx 2.11$.

2.3. Deduplicación

La guía afirma que los duplicados distorsionan resultados, sesgan el entrenamiento e inflan las métricas. Las tres afirmaciones se siguen de una observación sobre el riesgo empírico.

Proposición 2.14 (Un duplicado es un peso). *Sea $\hat{R}(f) = \frac{1}{n} \sum_{i=1}^n \ell(f(x_i), y_i)$ el riesgo empírico de una función f bajo una pérdida ℓ . Si el registro (x_1, y_1) aparece k veces en lugar de una, el riesgo empírico sobre los $n + k - 1$ registros es*

$$\hat{R}_k(f) = \frac{1}{n + k - 1} \left(k \ell(f(x_1), y_1) + \sum_{i=2}^n \ell(f(x_i), y_i) \right),$$

es decir, el riesgo ponderado en el que el registro duplicado tiene peso k y los demás peso 1.

Demostración. Las k copias contribuyen cada una $\ell(f(x_1), y_1)$ a la suma, y el total de registros es $n - 1 + k$. $\square$

En consecuencia, el minimizador de $\hat{R}_k$ se desplaza hacia ajustar mejor (x_1, y_1) a costa de los demás, y cualquier estadístico derivado (una media, un conteo como “transacciones en 24 horas”) trata ese registro como k observaciones independientes, lo que subestima varianzas y sesga conteos. Si una copia cae en $\mathcal{D}_{\text{tr}}$ y otra en $\mathcal{D}_{\text{te}}$, el modelo se evalúa en un punto con el que entrenó, lo que es fuga de datos en el sentido amplio; por eso la deduplicación debe hacerse antes de dividir. Los casi duplicados (“Juan Pérez” y “JUAN PEREZ”) son el mismo registro bajo una normalización de texto ν (pasar a mayúsculas, quitar acentos): se detectan comparando $\nu(z_i) = \nu(z_j)$ en lugar de $z_i = z_j$.

3. Selección y extracción de características

Motivación: la maldición de la dimensionalidad. La guía afirma que con muchas características “las observaciones quedan más dispersas”. Un cálculo lo precisa. Si los datos son uniformes en el cubo $[0, 1]^p$ y se quiere que un vecindario cúbico de cada punto contenga una fracción r de los datos, su lado debe ser ℓ con $\ell^p = r$, es decir, $\ell = r^{1/p}$. Para $r = 0.01$ y $p = 1$ basta $\ell = 0.01$; para $p = 10$ hace falta $\ell = 0.01^{1/10} \approx 0.63$, y para $p = 100$, $\ell \approx 0.955$. En dimensión alta, un “vecindario” que contenga el 1 % de los datos abarca casi todo el rango de cada coordenada y deja de ser local. Equivalentemente, para mantener fija la densidad de puntos por celda de lado ℓ se necesitan del orden de ℓ^{-p} observaciones, un número que crece exponencialmente con p . De ahí la necesidad de reducir p , que la guía divide en dos familias: *seleccionar* un subconjunto de las columnas o *extraer* columnas nuevas que combinen las originales.

3.1. Métodos de filtro

Un método de filtro puntúa cada característica X_j por su asociación con la respuesta Y , sin ajustar el modelo final, y conserva las de mayor puntuación. La guía menciona tres puntuaciones: correlación, información mutua y la prueba χ^2 .

La correlación de Pearson $\text{Corr}(X, Y) = \text{Cov}(X, Y) / \sqrt{\text{Var } X \text{Var } Y}$ es la puntuación más antigua, pero solo mide dependencia *lineal*.

Ejemplo 3.1 (Dependencia total con correlación nula). Sea X uniforme en $\{-1, 0, 1\}$ e $Y = X^2$. Entonces $\mathbb{E}[X] = 0$ y $\mathbb{E}[X^3] = \frac{1}{3}(-1 + 0 + 1) = 0$, así que $\text{Cov}(X, Y) = \mathbb{E}[X \cdot X^2] - \mathbb{E}[X]\mathbb{E}[X^2] = 0$ y la correlación es nula, aunque Y es una función exacta de X . Un filtro por correlación descartaría una característica perfectamente predictiva.

La información mutua, introducida por Shannon (1948) en teoría de la comunicación, detecta cualquier forma de dependencia.

Definición 3.2 (Información mutua). Para variables discretas X, Y con función de masa conjunta $p(x, y)$ y marginales $p(x), p(y)$, la *información mutua* es

$$I(X; Y) = \sum_{x, y: p(x, y) > 0} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}.$$

La definición compara la distribución conjunta con la que tendrían X e Y si fueran independientes, $p(x)p(y)$; el logaritmo del cociente vale cero exactamente cuando ambas coinciden en ese punto.

Teorema 3.3 (La información mutua caracteriza la independencia). $I(X; Y) \geq 0$, con igualdad si y solo si X e Y son independientes.

Demostración. Sea $S = \{(x, y) : p(x, y) > 0\}$. Usamos la desigualdad $\log t \leq t - 1$ para $t > 0$, con igualdad solo en $t = 1$ (la función $t - 1 - \log t$ tiene derivada $1 - 1/t$, negativa en $(0, 1)$ y positiva en $(1, \infty)$, y vale 0 en $t = 1$). Con $t = p(x)p(y)/p(x, y)$,

$$\begin{aligned} -I(X; Y) &= \sum_S p(x, y) \log \frac{p(x)p(y)}{p(x, y)} \leq \sum_S p(x, y) \left(\frac{p(x)p(y)}{p(x, y)} - 1 \right) \\ &= \sum_S p(x)p(y) - 1 \leq \sum_{x, y} p(x)p(y) - 1 = 0. \end{aligned}$$

Luego $I \geq 0$. Si hay igualdad, ambas desigualdades son igualdades. La primera exige $p(x)p(y) = p(x, y)$ en todo $(x, y) \in S$; la segunda exige $\sum_S p(x)p(y) = 1$, es decir, $p(x)p(y) = 0$ fuera de S , donde $p(x, y) = 0$. Juntas dan $p(x, y) = p(x)p(y)$ en todo punto, que es la independencia. Recíprocamente, si hay independencia cada logaritmo vale $\log 1 = 0$. $\square$

En el Ejemplo 3.1, Y vale 0 con probabilidad $1/3$ y 1 con probabilidad $2/3$, y dado X el valor de Y es determinista. Por la identidad $I(X; Y) = H(Y) - H(Y | X)$ (que se obtiene escribiendo $\log \frac{p(x, y)}{p(x)p(y)} = \log \frac{p(y|x)}{p(y)}$ y separando la suma), con $H(Y | X) = 0$ se obtiene $I(X; Y) = H(Y) = -\frac{1}{3} \log \frac{1}{3} - \frac{2}{3} \log \frac{2}{3} = \log 3 - \frac{2}{3} \log 2 > 0$. La información mutua detecta lo que la correlación no ve. Su desventaja es estadística: para variables continuas hay que estimar densidades o discretizar, y el estimador tiene sesgo y varianza apreciables con muestras pequeñas.

Para una característica categórica y una respuesta categórica, la prueba de independencia en una tabla de contingencia es la puntuación clásica, y está ligada a la información mutua.

Proposición 3.4 (Estadístico G e información mutua). Sea una tabla de contingencia con conteos observados O_{ab} , total n , marginales $O_{a.}, O_{.b}$ y conteos esperados bajo independencia $E_{ab} = O_{a.}O_{.b}/n$. Sea $\hat{I}$ la información mutua (con logaritmo natural) de la distribución empírica $\hat{p}(a, b) = O_{ab}/n$. Entonces el estadístico de razón de verosimilitudes $G = 2 \sum_{a, b} O_{ab} \log(O_{ab}/E_{ab})$ cumple $G = 2n\hat{I}$. Además, si $O_{ab} = E_{ab}(1 + \delta_{ab})$ con $\max |\delta_{ab}| \rightarrow 0$, entonces $G = \sum_{a, b} (O_{ab} - E_{ab})^2 / E_{ab} + o(\sum_{a, b} E_{ab} \delta_{ab}^2)$, es decir, G y el estadístico χ^2 de Pearson coinciden a segundo orden.

Demostración. Como $\hat{p}(a) = O_{a.}/n$ y $\hat{p}(b) = O_{.b}/n$, se tiene $\frac{\hat{p}(a, b)}{\hat{p}(a)\hat{p}(b)} = \frac{O_{ab}/n}{O_{a.}O_{.b}/n^2} = \frac{O_{ab}}{E_{ab}}$. Entonces $n\hat{I} = \sum_{a, b} n\hat{p}(a, b) \log \frac{O_{ab}}{E_{ab}} = \sum_{a, b} O_{ab} \log \frac{O_{ab}}{E_{ab}} = G/2$.

Para la segunda parte, el desarrollo de Taylor $(1 + \delta) \log(1 + \delta) = \delta + \frac{\delta^2}{2} + O(\delta^3)$ (producto de $1 + \delta$ por $\log(1 + \delta) = \delta - \frac{\delta^2}{2} + O(\delta^3)$) da $O_{ab} \log \frac{O_{ab}}{E_{ab}} = E_{ab}(\delta_{ab} + \frac{\delta_{ab}^2}{2} + O(\delta_{ab}^3))$. Sumando, $\sum_{a, b} E_{ab} \delta_{ab} = \sum_{a, b} (O_{ab} - E_{ab}) = n - n = 0$, porque la suma de los esperados es $\sum_{a, b} O_{a.}O_{.b}/n = n \cdot n/n = n$. Queda $G = \sum_{a, b} E_{ab} \delta_{ab}^2 + O(\sum E_{ab} |\delta_{ab}|^3)$, y $E_{ab} \delta_{ab}^2 = (O_{ab} - E_{ab})^2 / E_{ab}$. $\square$

Así, ordenar características categóricas por el estadístico χ^2 o por información mutua empírica da, para tablas del mismo tamaño y cerca de la independencia, el mismo orden. La prueba χ^2 añade un umbral de significación con la distribución asintótica $\chi^2_{(r-1)(c-1)}$; la información mutua se extiende a respuestas y características no categóricas.

3.2. Redundancia, colinealidad y fuga del objetivo

La guía elimina los ingresos porque “se mueven en paralelo a las ventas”. El caso extremo de ese paralelismo es la colinealidad exacta, que tiene una consecuencia algebraica precisa.

Proposición 3.5 (Colinealidad exacta). *Si alguna columna de X es combinación lineal de otras, entonces $X^\top X$ es singular y el estimador de mínimos cuadrados no es único.*

Demostración. Si $x_{\cdot k} = \sum_{j \neq k} c_j x_{\cdot j}$, el vector v con $v_k = -1$ y $v_j = c_j$ ($j \neq k$) es no nulo y cumple $Xv = 0$. Entonces $X^\top Xv = 0$, así que $X^\top X$ tiene núcleo no trivial y es singular. Si $\hat{\beta}$ resuelve las ecuaciones normales $X^\top X\beta = X^\top y$, también las resuelve $\hat{\beta} + tv$ para todo $t \in \mathbb{R}$, y todas producen las mismas predicciones $X\hat{\beta}$. $\square$

Con ingresos = precio $\times$ ventas y precio constante, la colinealidad es exacta y los coeficientes de ventas e ingresos no están identificados. Con colinealidad aproximada, $X^\top X$ es casi singular y la varianza de los coeficientes se dispara. La selección elimina la columna redundante; la extracción (PCA, abajo) la funde con su pareja.

Hay una razón más fuerte para descartar los ingresos del día al predecir las ventas del día: esos ingresos solo se conocen después de las ventas. Formalmente, si la predicción para el instante t se hace con la información disponible en t , toda característica debe ser función de esa información; una característica calculada con datos posteriores es *fuga del objetivo* (*target leakage*). Se formaliza con series de tiempo en la Sección 8.

3.3. Extracción lineal: análisis de componentes principales

Motivación. Pearson (1901) buscaba la recta o el plano que mejor se ajustan a una nube de puntos cuando todas las coordenadas tienen error, y Hotelling (1933) buscaba pocas combinaciones de muchas variables correlacionadas (pruebas psicológicas) que resumieran su variación. En ambos casos las características originales son redundantes y se busca un sistema de coordenadas con menos ejes que conserve lo esencial. La guía propone PCA después de one-hot y para imágenes; el objeto es el mismo.

Definición 3.6 (Componentes principales). Sea $X \in \mathbb{R}^{n \times p}$ con columnas centradas y $S = \frac{1}{n-1} X^\top X$ su matriz de covarianza muestral, simétrica y semidefinida positiva, con valores propios $\lambda_1 \geq \dots \geq \lambda_p \geq 0$ y vectores propios ortonormales $v_1, \dots, v_p$. La k -ésima *componente principal* de un registro x es $v_k^\top x$, y la *proporción de varianza explicada* por las q primeras es $\sum_{k \leq q} \lambda_k / \sum_{k \leq p} \lambda_k$.

La definición es la solución de un problema de optimización, que es lo que la hace natural.

Teorema 3.7 (Máxima varianza). *Para todo $w \in \mathbb{R}^p$ con $\|w\| = 1$, la varianza muestral de la proyección Xw es $w^\top Sw \leq \lambda_1$, con igualdad en $w = v_1$. Más en general, entre los w unitarios ortogonales a $v_1, \dots, v_{k-1}$, el máximo de $w^\top Sw$ es λ_k y se alcanza en $w = v_k$.*

Demostración. La varianza muestral de Xw (columna centrada, porque las de X lo son) es $\frac{1}{n-1} (Xw)^\top (Xw) = w^\top Sw$. Escribiendo $w = \sum_i a_i v_i$ en la base ortonormal, $\|w\|^2 = \sum_i a_i^2 = 1$

y, como $Sv_i = \lambda_i v_i$ y $v_i^\top v_j = \mathbf{1}[i=j]$, $w^\top Sw = \sum_i \lambda_i a_i^2$. Si $w \perp v_1, \dots, v_{k-1}$, entonces $a_1 = \dots = a_{k-1} = 0$ y $w^\top Sw = \sum_{i \geq k} \lambda_i a_i^2 \leq \lambda_k \sum_{i \geq k} a_i^2 = \lambda_k$, porque $\lambda_i \leq \lambda_k$ para $i \geq k$. La igualdad se alcanza con $a_k = 1$ y los demás nulos, es decir, $w = v_k$. El caso $k = 1$ es el primer enunciado. $\square$

PCA depende de la escala de las columnas, lo que obliga a estandarizar antes (Sección 4).

Ejemplo 3.8 (PCA sin estandarizar y con características redundantes). (a) Si dos características son incorrelacionadas con varianzas 1 y 10^4 (por ejemplo, la misma magnitud en metros y otra en centímetros), $S = \text{diag}(1, 10^4)$, la primera componente es el eje de la segunda característica y explica $10^4/(10^4 + 1) = 99.99\%$ de la varianza: PCA “descubre” la unidad de medida, no una estructura. Tras estandarizar, $S = I$, todo vector unitario tiene varianza 1 y no hay dirección privilegiada.

(b) Si dos características estandarizadas tienen correlación $\rho > 0$ (ventas e ingresos), su matriz de covarianza es $R = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}$. Se verifica que $R(1, 1)^\top = (1 + \rho)(1, 1)^\top$ y $R(1, -1)^\top = (1 - \rho)(1, -1)^\top$, así que $\lambda_1 = 1 + \rho$ con $v_1 = (1, 1)/\sqrt{2}$ y $\lambda_2 = 1 - \rho$. La primera componente, la suma normalizada de ambas, explica $(1 + \rho)/2$; con $\rho = 0.98$, el 99%. PCA funde las dos columnas redundantes en una.

Contraste selección frente a extracción. La selección conserva columnas originales, lo que preserva la interpretación y permite dejar de recolectar las descartadas; con filtros univariantes ignora interacciones (una característica inútil por sí sola puede ser útil combinada con otra). La extracción por PCA combina todas las columnas, por lo que sigue necesitando recolectarlas todas y pierde interpretación, pero aprovecha la redundancia (Ejemplo 3.8(b)). PCA es no supervisado: maximiza varianza de X sin mirar Y , y una dirección de poca varianza puede ser la más predictiva. Los vectores v_k son parámetros ajustados y deben estimarse con $\mathcal{D}_{\text{tr}}$.

4. Escalado de características numéricas

4.1. Por qué importa la escala

La guía afirma que el escalado evita que las características grandes “dominen” y acelera el descenso de gradiente. Antes de estudiar cada escalador conviene demostrar cuándo la escala importa y cuándo no, porque la respuesta depende del algoritmo. Se consideran cuatro casos.

(1) *Métodos basados en distancias.* La distancia euclídea $d(x, x')^2 = \sum_j (x_j - x'_j)^2$ es una suma de contribuciones por coordenada. Si la característica j se multiplica por c , su contribución se multiplica por c^2 . Con edad en años (diferencias típicas de 10) e ingreso en pesos (diferencias típicas de 10^4), la contribución del ingreso es del orden de 10^8 frente a 10^2 , y los vecinos más cercanos se deciden solo por el ingreso. Esto afecta a k vecinos, a k -medias y a las máquinas de vectores de soporte con núcleo radial.

(2) *Descenso de gradiente.* Para la pérdida cuadrática de la regresión lineal con columnas centradas, $L(\beta) = \frac{1}{2n} \|y - X\beta\|^2$, el gradiente es $\nabla L(\beta) = \frac{1}{n} X^\top (X\beta - y)$ y la matriz hessiana es $H = \frac{1}{n} X^\top X$. El siguiente teorema muestra que la velocidad del descenso de gradiente depende del número de condición de H , que la escala controla.

Teorema 4.1 (Descenso de gradiente en una cuadrática). *Sea $L(\beta) = \frac{1}{2}(\beta - \beta^*)^\top H(\beta - \beta^*) + c$ con H simétrica y valores propios $0 < \mu = \lambda_{\min} \leq \lambda_{\max} = L_H$, y sea $\kappa = L_H/\mu$. La iteración $\beta_{t+1} = \beta_t - \eta \nabla L(\beta_t)$ con $\eta = 2/(L_H + \mu)$ cumple*

$$\|\beta_t - \beta^*\| \leq \left(\frac{\kappa - 1}{\kappa + 1} \right)^t \|\beta_0 - \beta^*\|,$$

y ningún paso fijo η da un factor de contracción uniforme menor.

Demostración. Como $\nabla L(\beta) = H(\beta - \beta^*)$, se tiene $\beta_{t+1} - \beta^* = (I - \eta H)(\beta_t - \beta^*)$. La matriz $I - \eta H$ es simétrica con valores propios $1 - \eta \lambda_i$, así que su norma espectral es $\max_i |1 - \eta \lambda_i| \leq \max_{\lambda \in [\mu, L_H]} |1 - \eta \lambda|$. La función $\lambda \mapsto 1 - \eta \lambda$ es afín, por lo que el máximo de su valor absoluto en el intervalo se alcanza en un extremo: vale $\max(|1 - \eta \mu|, |1 - \eta L_H|)$. Este máximo se minimiza cuando $1 - \eta \mu = -(1 - \eta L_H)$, es decir, $\eta = 2/(L_H + \mu)$, y entonces vale $1 - \frac{2\mu}{L_H + \mu} = \frac{L_H - \mu}{L_H + \mu} = \frac{\kappa - 1}{\kappa + 1}$. Cualquier otro η aumenta uno de los dos términos, y ese término es el factor real sobre el vector propio correspondiente. Iterando la desigualdad $\|\beta_{t+1} - \beta^*\| \leq \frac{\kappa - 1}{\kappa + 1} \|\beta_t - \beta^*\|$ se obtiene la cota. $\square$

Si dos características incorrelacionadas tienen varianzas 1 y 10^4 , $H = \text{diag}(1, 10^4)$ (con n grande y columnas centradas), $\kappa = 10^4$ y el factor es 0.9998: reducir el error en un factor 10^6 exige $t \geq \ln(10^6)/(-\ln 0.9998) \approx 6.9 \times 10^4$ iteraciones. Tras estandarizar, H es la matriz de correlación, que aquí es I ; entonces $\kappa = 1$, el factor es 0 y basta una iteración. Esta es la razón real, que la guía enuncia sin demostrar, de que la estandarización acelere el entrenamiento de modelos lineales y redes neuronales: no se debe a que calculen distancias, sino al condicionamiento de la hessiana.

(3) *Mínimos cuadrados ordinarios y regularización.* Sin regularización, el escalado no cambia las predicciones.

Proposición 4.2 (Invariancia de MCO frente a transformaciones afines por columna). *Sea $\tilde{X} = XD + \mathbf{1}c^\top$ con D diagonal invertible y $c \in \mathbb{R}^p$ (cada columna se escala y se desplaza). Si el modelo incluye intercepto, los valores ajustados por mínimos cuadrados con $[\mathbf{1}, X]$ y con $[\mathbf{1}, \tilde{X}]$ coinciden.*

Demostración. Los valores ajustados son la proyección ortogonal de y sobre el espacio columna de la matriz de diseño. Cada columna de $\tilde{X}$ es $d_j x_{.j} + c_j \mathbf{1}$, que está en el espacio columna de $[\mathbf{1}, X]$; recíprocamente $x_{.j} = (\tilde{x}_{.j} - c_j \mathbf{1})/d_j$ está en el de $[\mathbf{1}, \tilde{X}]$. Los dos espacios columna coinciden, luego también las proyecciones. $\square$

Con penalización, en cambio, la escala sí importa. En la regresión ridge se minimiza $\|y - X\beta\|^2 + \alpha \|\beta\|^2$. Si una columna se multiplica por c , el coeficiente que produce la misma predicción se divide por c y su penalización se divide por c^2 : medir una característica en milímetros en vez de metros ($c = 1000$) reduce su penalización efectiva en un factor 10^6 . La estandarización hace que la penalización trate a todos los coeficientes en la misma escala. Esta es la segunda razón real por la que la guía recomienda estandarizar para regresión lineal y logística (que en la práctica suelen ajustarse con regularización).

(4) *Árboles de decisión.* Los árboles son invariantes a cualquier transformación estrictamente creciente de cada característica, no solo a las afines.

Proposición 4.3 (Invariancia de los cortes de un árbol). *Sea $g : \mathbb{R} \rightarrow \mathbb{R}$ estrictamente creciente. Para la muestra $x_{1j}, \dots, x_{nj}$ de una característica, la familia de particiones de $\{1, \dots, n\}$ de la forma $\{i : x_{ij} \leq t\}$, $t \in \mathbb{R}$, coincide con la familia de la forma $\{i : g(x_{ij}) \leq t'\}$, $t' \in \mathbb{R}$.*

Demostración. Como g es estrictamente creciente, $x_{ij} \leq x_{kj}$ si y solo si $g(x_{ij}) \leq g(x_{kj})$. Dado t , sea $A = \{i : x_{ij} \leq t\}$. Si A es vacío, se toma t' menor que todos los $g(x_{ij})$. Si no, sea $a = \max_{i \in A} x_{ij}$ y $t' = g(a)$: entonces $g(x_{ij}) \leq g(a)$ si y solo si $x_{ij} \leq a$, y $x_{ij} \leq a$ si y solo si $x_{ij} \leq t$ (porque ningún dato cae en $(a, t]$ por maximalidad de a). La inclusión recíproca es la misma con g^{-1} en lugar de g , que es estrictamente creciente en la imagen de g . $\square$

Como un árbol elige cada corte comparando la impureza de las particiones posibles, y estas coinciden, el árbol ajustado sobre $g(x_{.j})$ define las mismas regiones que sobre $x_{.j}$. Escalar, estandarizar o tomar logaritmos no cambia un árbol (salvo por desempates y por la posición exacta del umbral entre dos datos consecutivos).

4.2. La familia de escaladores afines

Los cuatro escaladores de la guía (MinMax, puntuación Z, robusto y MaxAbs) son casos de una misma construcción, y lo que los distingue es qué estadísticos se usan como posición y escala.

Definición 4.4 (Escalador afín). Un *escalador afín* de una columna es una transformación ajustada $T_{(c,s)}(x) = (x - c)/s$ con $s > 0$, donde $c = \hat{c}(\mathcal{D}_{\text{tr}})$ y $s = \hat{s}(\mathcal{D}_{\text{tr}})$ son estadísticos de posición y escala calculados con los datos de entrenamiento.

La elección de (c, s) da:

Escalador	c	s
MinMax (normalización)	$\min_i x_i$	$\max_i x_i - \min_i x_i$
Puntuación Z (estandarización)	$\bar{x}$	desviación estándar s_0
Robusto	mediana	IQR
MaxAbs	0	$\max_i x_i $

La guía repite en sus puntos esenciales que ninguno de estos escaladores “corrige el sesgo”. El resultado siguiente lo demuestra para toda la familia a la vez.

Proposición 4.5 (Los escaladores afines conservan la forma). *Sea X con momentos de tercer y cuarto orden finitos y $\sigma > 0$, y sea $Y = (X - c)/s$ con $s > 0$. Entonces la asimetría $\gamma_1 = \mathbb{E}[(X - \mu)^3]/\sigma^3$ y la curtosis $\gamma_2 = \mathbb{E}[(X - \mu)^4]/\sigma^4$ de Y coinciden con las de X . Más aún, la función de distribución de Y es $F_Y(y) = F_X(sy + c)$, de modo que Y tiene la misma forma que X salvo cambio de posición y unidad.*

Demostración. $\mathbb{E}[Y] = (\mu - c)/s$ y $Y - \mathbb{E}Y = (X - \mu)/s$, así que $\sigma_Y = \sigma/s$ y $\mathbb{E}[(Y - \mathbb{E}Y)^3]/\sigma_Y^3 = \frac{\mathbb{E}[(X - \mu)^3]/s^3}{\sigma^3/s^3} = \gamma_1(X)$; el cálculo para el cuarto momento es idéntico con exponente 4. Para la distribución, $F_Y(y) = \mathbb{P}((X - c)/s \leq y) = \mathbb{P}(X \leq sy + c)$ porque $s > 0$. $\square$

Todo cambio de forma exige una transformación no lineal (Sección 5). Lo que distingue a los escaladores afines entre sí es su comportamiento ante atípicos y ceros.

Proposición 4.6 (Propiedades de cada escalador). *Sea una columna $x_1, \dots, x_n$.*

- (i) Puntuación Z. *La columna transformada tiene media 0 y desviación estándar s_0 igual a 1.*
- (ii) MinMax. *La columna transformada tiene mínimo 0 y máximo 1. Si $n-1$ valores están en $[a, b]$, con a igual al mínimo de la columna, y el restante vale $M > b$, los $n-1$ valores transformados quedan en $[0, (b - a)/(M - a)]$, intervalo cuya longitud tiende a 0 cuando $M \rightarrow \infty$.*
- (iii) Robusto. *La mediana transformada es 0 y el IQR transformado es 1; reemplazar un único valor no acotado cambia la mediana y el IQR en una cantidad acotada (si $n \geq 5$).*
- (iv) MaxAbs. *Los valores transformados están en $[-1, 1]$, conservan el signo y $T(0) = 0$. En consecuencia, si la columna tiene una fracción π de ceros, la transformada también, mientras que la puntuación Z y MinMax convierten los ceros en $-\bar{x}/s_0$ y $-\min x/(\max x - \min x)$, que son no nulos salvo que $\bar{x} = 0$ o $\min x = 0$.*

Demostración. (i) La media de $(x_i - \bar{x})/s_0$ es $(\bar{x} - \bar{x})/s_0 = 0$ y su desviación estándar es $s_0/s_0 = 1$ por el cálculo de la Proposición 4.5.

(ii) T es creciente, así que lleva el mínimo a $(\min x - \min x)/(\max x - \min x) = 0$ y el máximo a 1. Con mínimo a y máximo M , un valor $x \in [a, b]$ se lleva a $(x - a)/(M - a) \in [0, (b - a)/(M - a)]$, porque $0 \leq x - a \leq b - a$. La cota $(b - a)/(M - a)$ tiende a 0 cuando $M \rightarrow \infty$.

(iii) La mediana y el IQR de la columna transformada son $(\text{med} - \text{med})/\text{IQR} = 0$ y $\text{IQR}/\text{IQR} = 1$, porque la transformación es afín creciente y los cuantiles de una transformación afín creciente son la transformación de los cuantiles (la interpolación lineal entre estadísticos de orden conmuta con las funciones afines crecientes). Que un solo valor no los arrastre es la Proposición 2.10, ya que $1/n < 1/4$ para $n \geq 5$.

(iv) $|x_i/\max_k |x_k|| \leq 1$, el signo no cambia al dividir entre un positivo y $0/s = 0$. Las fórmulas para los otros escaladores son $T(0) = (0 - c)/s$. $\square$

La parte (iv) es la razón por la que la guía recomienda MaxAbs para datos dispersos: una matriz documento–término con 99.9% de ceros se guarda almacenando solo las entradas no nulas; tras centrar, todas las entradas serían no nulas y la memoria se multiplicaría por mil. La parte (ii) es la debilidad de MinMax: en el ejemplo de la guía con $x = 25$ como máximo, los otros nueve valores de x , que están en $[3.8, 14]$, se llevan a $[0, 0.48]$.

Contraste. La guía resume: normalización cuando importa el rango, estandarización cuando importa la distribución. Con lo demostrado, el contraste preciso es este.

- *MinMax*: garantiza un rango acotado $[0, 1]$ (útil para entradas que deben estar acotadas, como intensidades de píxeles o funciones de activación que se saturan), pero su escala depende de dos estadísticos con punto de ruptura $1/n$; un valor nuevo fuera del rango de entrenamiento se transforma fuera de $[0, 1]$.
- *Puntuación Z*: produce media 0 y varianza 1, que es lo que condiciona bien la hessiana (Teorema 4.1) y homogeneiza las penalizaciones; no acota el rango y su escala se infla con atípicos. No normaliza la distribución (Proposición 4.5): la frase de la guía “ideal para algoritmos que asumen normalidad” debe leerse con ese matiz, y además la regresión lineal supone normalidad de los errores, no de las características.
- *Robusto*: sus parámetros resisten atípicos, pero el atípico sigue siendo atípico tras la transformación (es afín); en el ejemplo de la guía, $y = 23$ se lleva a $(23 - 8.25)/5.375 = 2.744$, lejos del resto, cuyo máximo es 0.791.
- *MaxAbs*: el único que conserva ceros y dispersión; hereda la sensibilidad de MinMax a un máximo extremo.

5. Transformaciones no lineales

Motivación. La Proposición 4.5 muestra que ningún escalador afín cambia la asimetría. Los modelos lineales clásicos, sin embargo, funcionan mejor cuando la relación con la respuesta es aditiva y la varianza de los errores es constante, y muchas magnitudes reales (ingresos, tiempos, concentraciones, conteos) son asimétricas a la derecha y tienen varianza que crece con la media. Tukey (1957) organizó las transformaciones de potencia $x \mapsto x^\lambda$ en una “escalera” según su fuerza, y Box y Cox (1964) propusieron elegir λ por máxima verosimilitud para lograr a la vez normalidad aproximada, varianza constante y aditividad. Yeo y Johnson (2000) extendieron la familia a datos con ceros y negativos. Esta sección demuestra por qué estas transformaciones reducen la asimetría, las ordena por fuerza y deriva sus estimadores.

5.1. Asimetría por cuantiles y transformaciones cóncavas

Para comparar transformaciones hace falta una medida de asimetría que se comporte bien bajo funciones crecientes. La asimetría por momentos no sirve para esto (los momentos de $g(X)$ no son funciones de los de X), pero los cuantiles sí se transportan.

Definición 5.1 (Función cuantil y razón de colas). Sea F la función de distribución de X y $Q(u) = \inf\{x : F(x) \geq u\}$, $u \in (0, 1)$, su función cuantil. Para $u \in (0, \frac{1}{2})$ con $Q(u) < Q(\frac{1}{2}) < Q(1 - u)$ se define la *razón de colas*

$$R_u(X) = \frac{Q(1 - u) - Q(\frac{1}{2})}{Q(\frac{1}{2}) - Q(u)},$$

y la *asimetría por cuantiles* $B_u(X) = \frac{Q(1 - u) + Q(u) - 2Q(\frac{1}{2})}{Q(1 - u) - Q(u)}$.

R_u compara la distancia de la mediana al cuantil superior con la distancia al cuantil inferior: $R_u > 1$ indica cola derecha más larga, $R_u = 1$ simetría en esos cuantiles. Dividiendo numerador y denominador de B_u entre $Q(\frac{1}{2}) - Q(u)$ se obtiene $B_u = (R_u - 1)/(R_u + 1)$, que es función creciente de R_u (su derivada es $2/(R_u + 1)^2 > 0$) y toma valores en $(-1, 1)$; con $u = \frac{1}{4}$, B_u es el coeficiente de Bowley. Ambas medidas son invariantes a transformaciones afines crecientes, lo que concuerda con la Proposición 4.5.

Lema 5.2 (Los cuantiles se transportan). Sea I un intervalo abierto con $\mathbb{P}(X \in I) = 1$ y $g : I \rightarrow \mathbb{R}$ continua y estrictamente creciente. Entonces $Q_{g(X)}(u) = g(Q_X(u))$ para todo $u \in (0, 1)$.

Demostración. Sea $q = Q_X(u)$, que pertenece a la clausura de I ; supondremos $q \in I$ (el caso de un extremo se trata igual con límites). Como g es estrictamente creciente, $g(X) \leq g(x)$ si y solo si $X \leq x$, así que $\mathbb{P}(g(X) \leq g(x)) = F(x)$ para $x \in I$. Por continuidad por la derecha de F , $F(q) \geq u$, luego $\mathbb{P}(g(X) \leq g(q)) \geq u$ y $Q_{g(X)}(u) \leq g(q)$. Sea ahora $y < g(q)$. Si y es menor que todos los valores de g en I , $\mathbb{P}(g(X) \leq y) = 0 < u$. En otro caso, por el teorema del valor intermedio (la imagen de I por g continua es un intervalo) existe $x \in I$ con $g(x) = y$ y, como g es creciente, $x < q$; por definición de ínfimo, $F(x) < u$, es decir, $\mathbb{P}(g(X) \leq y) < u$. Luego ningún $y < g(q)$ está en el conjunto que define $Q_{g(X)}(u)$, y $Q_{g(X)}(u) = g(q)$. $\square$

Lema 5.3 (Pendientes de cuerdas de una función cóncava). Si g es cóncava en un intervalo que contiene a $a < b < c$, entonces

$$\frac{g(c) - g(b)}{c - b} \leq \frac{g(c) - g(a)}{c - a} \leq \frac{g(b) - g(a)}{b - a},$$

con desigualdades estrictas si g es estrictamente cóncava.

Demostración. Sea $t = \frac{c-b}{c-a} \in (0, 1)$, de modo que $b = ta + (1 - t)c$ (se verifica: $ta + (1 - t)c = c - t(c - a) = c - (c - b) = b$). La concavidad da $g(b) \geq tg(a) + (1 - t)g(c)$. Restando $g(a)$ a ambos lados, $g(b) - g(a) \geq (1 - t)(g(c) - g(a))$, y como $1 - t = \frac{b-a}{c-a}$, dividiendo entre $b - a > 0$ se obtiene la desigualdad derecha. Restando la desigualdad de concavidad de $g(c)$, $g(c) - g(b) \leq t(g(c) - g(a))$; dividiendo entre $c - b = t(c - a)$ se obtiene la izquierda. Con concavidad estricta la primera desigualdad es estricta y también lo son las siguientes. $\square$

Teorema 5.4 (Las transformaciones cóncavas reducen la asimetría derecha). Sea g continua, estrictamente creciente y cóncava en un intervalo abierto I con $\mathbb{P}(X \in I) = 1$, y sea $u \in (0, \frac{1}{2})$ tal que $Q(u) < Q(\frac{1}{2}) < Q(1 - u)$. Entonces $R_u(g(X)) \leq R_u(X)$ y $B_u(g(X)) \leq B_u(X)$, con desigualdades estrictas si g es estrictamente cóncava. Si g es convexa, las desigualdades se invierten.

Demostración. Escribimos $a = Q_X(u)$, $b = Q_X(\frac{1}{2})$, $c = Q_X(1-u)$, con $a < b < c$. Por el Lema 5.2, los cuantiles correspondientes de $g(X)$ son $g(a) < g(b) < g(c)$ (estrictamente, porque g es estrictamente creciente). Por tanto

$$R_u(g(X)) = \frac{g(c) - g(b)}{g(b) - g(a)} = \frac{\frac{g(c)-g(b)}{c-b}}{\frac{g(b)-g(a)}{b-a}} \cdot \frac{c-b}{b-a} = \frac{m_{\sup}}{m_{\inf}} R_u(X),$$

donde $m_{\sup}$ y $m_{\inf}$ son las pendientes de las cuerdas sobre $[b, c]$ y $[a, b]$, ambas positivas. Por el Lema 5.3, $m_{\sup} \leq m_{\inf}$, luego $R_u(g(X)) \leq R_u(X)$, con desigualdad estricta si g es estrictamente cóncava. Como B_u es función creciente de R_u , lo mismo vale para B_u . Si g es convexa, $-g$ es cóncava y el Lema 5.3 aplicado a $-g$ invierte la desigualdad entre pendientes. $\square$

El teorema es la versión precisa de la frase de la guía “la transformación logarítmica comprime la cola derecha”: cualquier transformación creciente y cóncava acorta la distancia entre la mediana y los cuantiles altos en relación con la distancia a los cuantiles bajos. También explica el riesgo opuesto: aplicada a datos simétricos ($R_u = 1$), una transformación estrictamente cóncava produce $R_u < 1$, es decir, asimetría a la izquierda.

Ejemplo 5.5 (El ejemplo de la guía). Para $y = (4.7, 5, 6, 7.5, 8, 8.5, 11, 12, 12.5, 23)$ (ordenado), con la definición de cuantil del Lema 5.2 ($Q(u)$ es el menor dato con frecuencia acumulada $\geq u$): $Q(\frac{1}{4}) = 6$, $Q(\frac{1}{2}) = 8$, $Q(\frac{3}{4}) = 12$, así que $R_{1/4}(y) = (12 - 8)/(8 - 6) = 2$. Para $\log_{10} y$, por el Lema 5.2 los cuantiles son $\log_{10} 6 = 0.7782$, $\log_{10} 8 = 0.9031$ y $\log_{10} 12 = 1.0792$, y $R_{1/4} = 0.1761/0.1249 \approx 1.41$. En términos de Bowley, B pasa de $1/3$ a 0.17 . (La asimetría por momentos pasa de 1.49 a 0.52 .)

5.2. La escalera de potencias y la familia de Box–Cox

Definición 5.6 (Transformación de Box–Cox). Para $x > 0$ y $\lambda \in \mathbb{R}$,

$$\text{BC}_\lambda(x) = \begin{cases} \frac{x^\lambda - 1}{\lambda}, & \lambda \neq 0, \\ \log x, & \lambda = 0. \end{cases}$$

La resta de 1 y la división entre λ parecen arbitrarias, pero son lo que hace de la familia un objeto continuo en λ en el que el logaritmo ocupa su lugar natural. Sin ellas, x^λ tiende a la constante 1 cuando $\lambda \rightarrow 0$ y la familia pierde el logaritmo; y para $\lambda < 0$, x^λ es decreciente e invertiría el orden de los datos.

Proposición 5.7 (Propiedades de Box–Cox). Para cada $x > 0$: (i) $\lambda \mapsto \text{BC}_\lambda(x)$ es continua, en particular $\lim_{\lambda \rightarrow 0} \text{BC}_\lambda(x) = \log x$; (ii) para cada λ , $x \mapsto \text{BC}_\lambda(x)$ es estrictamente creciente con derivada $x^{\lambda-1}$; (iii) es estrictamente cóncava si $\lambda < 1$, afín si $\lambda = 1$ y estrictamente convexa si $\lambda > 1$; (iv) $\text{BC}_\lambda(1) = 0$ para todo λ .

Demostración. (i) Para $\lambda \neq 0$, $\text{BC}_\lambda(x) = \frac{e^{\lambda \log x} - e^0}{\lambda - 0}$ es el cociente incremental en 0 de la función $\lambda \mapsto e^{\lambda \log x}$, cuya derivada en 0 es $\log x \cdot e^0 = \log x$. (ii) Para $\lambda \neq 0$, $\frac{d}{dx} \frac{x^\lambda - 1}{\lambda} = x^{\lambda-1}$, y para $\lambda = 0$, $\frac{d}{dx} \log x = x^{-1} = x^{0-1}$; en ambos casos la derivada es positiva en $x > 0$. (iii) La segunda derivada es $(\lambda - 1)x^{\lambda-2}$, cuyo signo es el de $\lambda - 1$. (iv) $1^\lambda - 1 = 0$ y $\log 1 = 0$. $\square$

Por (iii) y el Teorema 5.4, toda BC_λ con $\lambda < 1$ reduce la asimetría derecha. La guía dice que la raíz cuadrada tiene un efecto “menos marcado” que el logaritmo; el resultado siguiente lo demuestra y ordena toda la familia.

Teorema 5.8 (Orden de fuerza en la escalera de potencias). *Si $\lambda_2 < \lambda_1$, existe h continua, estrictamente creciente y cóncava tal que $\text{BC}_{\lambda_2} = h \circ \text{BC}_{\lambda_1}$ en $(0, \infty)$. En consecuencia, para $X > 0$ y u como en el Teorema 5.4, $R_u(\text{BC}_{\lambda_2}(X)) \leq R_u(\text{BC}_{\lambda_1}(X))$. En particular, para datos positivos,*

$$R_u(X) \geq R_u(\sqrt{X}) \geq R_u(\sqrt[3]{X}) \geq R_u(\log X).$$

Demostración. Por la Proposición 5.7(ii), BC_{λ_1} es una biyección continua estrictamente creciente de $(0, \infty)$ sobre su imagen J , que es un intervalo; sea $h = \text{BC}_{\lambda_2} \circ \text{BC}_{\lambda_1}^{-1} : J \rightarrow \mathbb{R}$, que es continua y estrictamente creciente por ser composición de funciones con esas propiedades. Por la regla de la cadena y la derivada de la función inversa, para $u \in J$ y $x = \text{BC}_{\lambda_1}^{-1}(u)$,

$$h'(u) = \frac{\text{BC}'_{\lambda_2}(x)}{\text{BC}'_{\lambda_1}(x)} = \frac{x^{\lambda_2-1}}{x^{\lambda_1-1}} = x^{\lambda_2-\lambda_1}.$$

Como $\lambda_2 - \lambda_1 < 0$, $x \mapsto x^{\lambda_2-\lambda_1}$ es decreciente, y como $x = \text{BC}_{\lambda_1}^{-1}(u)$ es creciente en u , h' es decreciente en J . Una función derivable con derivada decreciente es cóncava (por el teorema del valor medio, las pendientes de las cuerdas sobre intervalos consecutivos son valores de h' en puntos ordenados, y por tanto decrecen, que es la condición de cuerdas del Lema 5.3). Aplicando el Teorema 5.4 a la variable $\text{BC}_{\lambda_1}(X)$ y a la función h se obtiene la desigualdad.

Para la cadena final, $\text{BC}_1(x) = x - 1$, $\text{BC}_{1/2}(x) = 2(\sqrt{x} - 1)$, $\text{BC}_{1/3}(x) = 3(\sqrt[3]{x} - 1)$ y $\text{BC}_0 = \log$. Cada una difiere de x , $\sqrt{x}$, $\sqrt[3]{x}$ en una función afín creciente, y R_u es invariante a tales funciones (sus cuantiles se transforman afinmente por el Lema 5.2 y el cociente de diferencias no cambia). Basta aplicar la primera parte con $1 > \frac{1}{2} > \frac{1}{3} > 0$. $\square$

La escalera es, pues, una familia totalmente ordenada por concavidad: bajar λ comprime más la cola derecha, subirlo por encima de 1 comprime la izquierda. Esto convierte la elección de transformación en la elección de un número, que es lo que hace posible estimarla.

Estimación de λ por máxima verosimilitud. Box y Cox supusieron que para algún λ las variables $\text{BC}_\lambda(X_i)$ son i.i.d. $N(\mu, \sigma^2)$. La densidad de X_i se obtiene por cambio de variable: si $Y = \text{BC}_\lambda(X)$ con BC_λ creciente y derivable, $f_X(x) = f_Y(\text{BC}_\lambda(x)) \text{BC}'_\lambda(x) = f_Y(\text{BC}_\lambda(x)) x^{\lambda-1}$. La log-verosimilitud de la muestra es entonces

$$\ell(\lambda, \mu, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (\text{BC}_\lambda(x_i) - \mu)^2 + (\lambda - 1) \sum_{i=1}^n \log x_i. \quad (2)$$

Para λ fijo, maximizar en μ y σ^2 es el problema normal usual: $\hat{\mu}(\lambda)$ es la media de los $\text{BC}_\lambda(x_i)$ y $\hat{\sigma}^2(\lambda) = \frac{1}{n} \sum_i (\text{BC}_\lambda(x_i) - \hat{\mu}(\lambda))^2$. Sustituyendo, el segundo término vale $-n/2$, y la log-verosimilitud perfilada es

$$\ell_p(\lambda) = -\frac{n}{2} \log \hat{\sigma}^2(\lambda) + (\lambda - 1) \sum_{i=1}^n \log x_i + \text{const.} \quad (3)$$

El estimador es $\hat{\lambda} = \arg \max_\lambda \ell_p(\lambda)$, que se calcula numéricamente; es lo que hace **PowerTransformer** de scikit-learn.

Observación 5.9 (Por qué el término jacobiano es imprescindible). Si se omitiera $(\lambda - 1) \sum \log x_i$ y se maximizara solo $-\frac{n}{2} \log \hat{\sigma}^2(\lambda)$, el problema sería degenerado. Supóngase que todos los $x_i > 1$. Para $\lambda < 0$, $\text{BC}_\lambda(x_i) = \frac{1-x_i^\lambda}{|\lambda|} \in (0, \frac{1}{|\lambda|})$, porque $0 < x_i^\lambda < 1$. Todos los valores transformados quedan en un intervalo de longitud $1/|\lambda|$, así que $\hat{\sigma}^2(\lambda) \leq 1/\lambda^2 \rightarrow 0$ cuando $\lambda \rightarrow -\infty$, y $-\frac{n}{2} \log \hat{\sigma}^2(\lambda) \rightarrow +\infty$. El “mejor” λ sería $-\infty$ solo porque encoge la escala. El jacobiano compensa exactamente ese cambio de escala, porque mide cuánto estira o encoge BC_λ el eje en cada dato.

5.3. Yeo–Johnson: ceros y negativos

Box–Cox exige $x > 0$. El remedio de desplazar, $BC_\lambda(x + k)$, introduce un segundo parámetro k sin una elección natural. Yeo y Johnson buscaron una familia definida en todo $\mathbb{R}$ que coincidiera con Box–Cox para datos positivos (desplazados en 1), que tratara la parte negativa con la reflexión adecuada y que conservara la continuidad y el orden por concavidad.

Definición 5.10 (Transformación de Yeo–Johnson). Para $x \in \mathbb{R}$ y $\lambda \in \mathbb{R}$,

$$YJ_\lambda(x) = \begin{cases} BC_\lambda(x + 1) = \frac{(x + 1)^\lambda - 1}{\lambda} (\log(x + 1) \text{ si } \lambda = 0), & x \geq 0, \\ -BC_{2-\lambda}(1 - x) = -\frac{(1 - x)^{2-\lambda} - 1}{2 - \lambda} (-\log(1 - x) \text{ si } \lambda = 2), & x < 0. \end{cases}$$

La rama negativa es la reflexión $x \mapsto -YJ(-x)$ de una Box–Cox con exponente $2 - \lambda$. La elección $2 - \lambda$ no es arbitraria: es la que hace que la segunda derivada tenga el mismo signo en ambas ramas, como se verá en (iii).

Proposición 5.11 (Propiedades de Yeo–Johnson). (i) YJ_λ es continua y derivable en 0, con $YJ_\lambda(0) = 0$ y $YJ'_\lambda(0) = 1$. (ii) Es estrictamente creciente en $\mathbb{R}$, con derivada $(x + 1)^{\lambda-1}$ si $x \geq 0$ y $(1 - x)^{1-\lambda}$ si $x < 0$. (iii) Es estrictamente cóncava en $\mathbb{R}$ si $\lambda < 1$, la identidad si $\lambda = 1$ y estrictamente convexa si $\lambda > 1$. (iv) El logaritmo del jacobiano de la muestra es $(\lambda - 1) \sum_i \text{sgn}(x_i) \log(|x_i| + 1)$, con $\text{sgn}(0) = 1$.

Demostración. (i) Ambas ramas valen 0 en $x = 0$: $BC_\lambda(1) = 0$ y $-BC_{2-\lambda}(1) = 0$ por la Proposición 5.7(iv). (ii) Para $x > 0$, la derivada es $BC'_\lambda(x + 1) = (x + 1)^{\lambda-1}$. Para $x < 0$, por la regla de la cadena, $\frac{d}{dx}[-BC_{2-\lambda}(1 - x)] = BC'_{2-\lambda}(1 - x) = (1 - x)^{1-\lambda}$. Ambas son positivas y ambas tienden a 1 en $x = 0$, lo que junto con la continuidad da (i). (iii) Para $x > 0$ la segunda derivada es $(\lambda - 1)(x + 1)^{\lambda-2}$; para $x < 0$ es $\frac{d}{dx}(1 - x)^{1-\lambda} = -(1 - \lambda)(1 - x)^{-\lambda} = (\lambda - 1)(1 - x)^{-\lambda}$. En ambas ramas el signo es el de $\lambda - 1$, y como la derivada primera es continua en 0, la derivada es estrictamente monótona en todo $\mathbb{R}$, lo que da concavidad o convexidad estricta global. Si $\lambda = 1$: para $x \geq 0$, $(x + 1) - 1 = x$; para $x < 0$, $-((1 - x) - 1) = x$. (iv) El jacobiano es el producto de las derivadas de (ii); su logaritmo es $\sum_{x_i \geq 0} (\lambda - 1) \log(x_i + 1) + \sum_{x_i < 0} (1 - \lambda) \log(1 - x_i)$, que es la expresión enunciada porque $1 - x_i = |x_i| + 1$ si $x_i < 0$. $\square$

Por (iii) y el Teorema 5.4, $\lambda < 1$ reduce la asimetría derecha y $\lambda > 1$ la izquierda, en todo $\mathbb{R}$. La estimación de λ es la de Box–Cox con el jacobiano de (iv) en lugar de $(\lambda - 1) \sum \log x_i$. En el ejemplo de la guía con datos simétricos ($\{1, 3, 5, 7, -1, -3\}$ y $\{2, 4, 6, 8, -2, -4\}$), las $\hat{\lambda}$ estimadas son 0.915 y 1.023, cercanas a 1: el estimador reconoce que no hay asimetría que corregir. **PowerTransformer** estandariza además la salida por defecto, por lo que el resultado tiene media 0 y varianza 1.

5.4. Estabilización de la varianza

La otra motivación de Box y Cox era la varianza no constante. Si la varianza de una medición crece con su media, un modelo con errores homocedásticos no es adecuado. El método delta indica qué transformación la estabiliza.

Teorema 5.12 (Método delta). Sean T_n variables aleatorias con $\sqrt{n}(T_n - \theta) \xrightarrow{d} N(0, v(\theta))$ y g con derivada continua en un entorno de θ . Entonces $\sqrt{n}(g(T_n) - g(\theta)) \xrightarrow{d} N(0, g'(\theta)^2 v(\theta))$.

Demostración. Por el teorema del valor medio, $g(T_n) - g(\theta) = g'(\xi_n)(T_n - \theta)$ con ξ_n entre T_n y θ (cuando T_n está en el entorno donde g es derivable, lo que ocurre con probabilidad que tiende a 1). Como $\sqrt{n}(T_n - \theta)$ converge en distribución, $T_n - \theta = n^{-1/2} \cdot \sqrt{n}(T_n - \theta) \rightarrow 0$ en probabilidad; luego $\xi_n \rightarrow \theta$ en probabilidad y, por continuidad de g' , $g'(\xi_n) \rightarrow g'(\theta)$ en probabilidad. Por el teorema de Slutsky, $\sqrt{n}(g(T_n) - g(\theta)) = g'(\xi_n)\sqrt{n}(T_n - \theta) \xrightarrow{d} g'(\theta) N(0, v(\theta))$, que es $N(0, g'(\theta)^2 v(\theta))$. $\square$

Para que la varianza límite no dependa de θ se necesita $g'(\theta)^2 v(\theta) = \text{const}$, es decir, $g'(\theta) \propto v(\theta)^{-1/2}$.

Corolario 5.13 (Raíz para conteos, logaritmo para magnitudes multiplicativas). (i) Si T_n es la media de n variables Poisson(θ), $v(\theta) = \theta$ y $g(t) = 2\sqrt{t}$ da varianza límite 1. (ii) Si T_n es la media de n exponenciales de media θ , $v(\theta) = \theta^2$ y $g(t) = \log t$ da varianza límite 1.

Demostración. Por el teorema central del límite, $\sqrt{n}(T_n - \theta) \rightarrow N(0, v(\theta))$ con v la varianza de una observación: θ para la Poisson y θ^2 para la exponencial. (i) $g'(\theta) = \theta^{-1/2}$ y $g'(\theta)^2 \theta = 1$. (ii) $g'(\theta) = \theta^{-1}$ y $g'(\theta)^2 \theta^2 = 1$. En ambos casos g tiene derivada continua en $\theta > 0$ y se aplica el Teorema 5.12. $\square$

Este es el fundamento de la afirmación de la guía de que la raíz y las transformaciones de potencia “estabilizan la varianza”: la raíz cuadrada corresponde a varianza proporcional a la media (conteos), el logaritmo a desviación estándar proporcional a la media (magnitudes con error relativo constante, como ingresos o precios).

5.5. Logaritmo y raíces: casos particulares y contraste

Linealización. El logaritmo convierte relaciones multiplicativas en aditivas: si $y = a b^x$ con $a, b > 0$, entonces $\log_{10} y = \log_{10} a + x \log_{10} b$, que es afín en x . En el ejemplo de la guía, $y = 10^{x-3}$ para $x = 3, 4, 5, 6$ da $y = 1, 10, 100, 1000$, y $\log_{10} y = x - 3$ es una recta exacta. Del mismo modo, un modelo multiplicativo $y = \beta_0 x_1^{\beta_1} x_2^{\beta_2} \varepsilon$ se vuelve lineal en $\log y$, $\log x_1$ y $\log x_2$ con error aditivo $\log \varepsilon$.

Ceros y negativos. $\log x$ solo está definido para $x > 0$. Para conteos con ceros se usa $\log(1 + x)$, que coincide con $YJ_0(x)$ para $x \geq 0$ y con $BC_0(x + 1)$: la Proposición 5.11 lo sitúa en la familia de Yeo–Johnson. La raíz cuadrada está definida en $[0, \infty)$ y es $BC_{1/2}$ salvo una función afín. La raíz cúbica está definida en todo $\mathbb{R}$ y es impar y estrictamente creciente, pero es cóncava en $(0, \infty)$ y convexa en $(-\infty, 0)$ (su segunda derivada es $-\frac{2}{9}x^{-5/3}$, de signo opuesto al de x). Por el Teorema 5.4, en datos de un solo signo reduce la asimetría hacia la mediana; en datos con ambos signos comprime ambas colas hacia cero y no corrige una asimetría en una dirección determinada. Además su derivada $\frac{1}{3}x^{-2/3}$ no está acotada en 0, así que separa mucho valores pequeños cercanos a cero, lo que puede amplificar ruido de medición.

Contraste.

Transformación	Dominio	Parámetro ajustado	Efecto y limitaciones
$\log x, \log(1+x)$	$x > 0; x > -1$	ninguno	la más fuerte de las fijas; lineariza modelos multiplicativos; estabiliza varianza $\propto$ media ² ; puede sobre corregir datos casi simétricos
$\sqrt{x}$	$x \geq 0$	ninguno	más débil que el logaritmo (Teorema 5.8); estabiliza varianza de conteos
$\sqrt[3]{x}$	$\mathbb{R}$	ninguno	entre la raíz cuadrada y el logaritmo en datos positivos; con ambos signos comprime las dos colas
Box-Cox	$x > 0$	λ por MV	elige la fuerza con los datos; requiere positividad
Yeo-Johnson	$\mathbb{R}$	λ por MV	como Box-Cox en $\mathbb{R}$; λ difícil de interpretar si hay ambos signos

Todas son estrictamente crecientes, por lo que (Proposición 4.3) no cambian nada en un árbol y solo tienen efecto en modelos que usan los valores de forma aditiva o métrica. Los parámetros λ se estiman con $\mathcal{D}_{\text{tr}}$. Frente al escalado robusto, que resiste atípicos pero no cambia la forma, estas transformaciones cambian la forma y acercan el atípico al resto sin eliminarlo.

6. Discretización

Motivación. La relación entre una característica continua y la respuesta puede no ser lineal ni monótona (la edad frente al riesgo de un seguro, que es alto en jóvenes y en mayores). Antes de los modelos flexibles, la forma más sencilla de capturarla con un modelo lineal era partir el rango en intervalos y estimar un nivel por intervalo. La guía presenta la discretización como paso de lo numérico a lo categórico; su contenido matemático es la aproximación por funciones escalonadas.

Definición 6.1 (Discretización). Dados cortes $-\infty = t_0 < t_1 < \dots < t_{B-1} < t_B = \infty$, la *discretización* de x es el índice $b(x) = k$ si $x \in (t_{k-1}, t_k]$. Es de *ancho igual* si $t_k - t_{k-1} = h$ constante para $2 \leq k \leq B-1$, y *por cuantiles* si $t_k = \hat{Q}(k/B)$ para los cuantiles empíricos de $\mathcal{D}_{\text{tr}}$. La codificación *one-hot* de $b(x)$ es el vector $(\mathbf{1}[b(x) = 1], \dots, \mathbf{1}[b(x) = B])$.

Proposición 6.2 (Modelo lineal sobre intervalos: medias por celda). Sea $G : \{1, \dots, n\} \rightarrow \{1, \dots, B\}$ una asignación de registros a grupos, todos no vacíos, y sea $D \in \mathbb{R}^{n \times B}$ la matriz de indicadores $D_{ik} = \mathbf{1}[G(i) = k]$. El ajuste por mínimos cuadrados de $y \approx D\gamma$ tiene solución única $\hat{\gamma}_k = \bar{y}_k$, la media de y en el grupo k .

Demostración. Cada fila de D tiene exactamente un 1, así que $(D^\top D)_{kl} = \sum_i D_{ik} D_{il} = n_k \mathbf{1}[k = l]$,

donde $n_k > 0$ es el tamaño del grupo k ; $D^\top D$ es diagonal invertible. Además $(D^\top y)_k = \sum_{i:G(i)=k} y_i$. Las ecuaciones normales $D^\top D\gamma = D^\top y$ dan $n_k\gamma_k = \sum_{G(i)=k} y_i$, es decir, $\gamma_k = \bar{y}_k$. $\square$

Así, discretizar y codificar en one-hot convierte cualquier modelo lineal en uno que ajusta un nivel constante por intervalo. La calidad de esa aproximación depende del ancho de los intervalos.

Proposición 6.3 (Error de aproximación escalonada). *Si f es L -Lipschitz en un intervalo $[a, a+h]$, la constante $c = f(a+h/2)$ cumple $\sup_{x \in [a, a+h]} |f(x) - c| \leq Lh/2$. La cota no puede mejorarse: para $f(x) = Lx$, $\min_c \sup_{x \in [a, a+h]} |f(x) - c| = Lh/2$.*

Demostración. Para $x \in [a, a+h]$, $|x - (a+h/2)| \leq h/2$ y, por la condición de Lipschitz, $|f(x) - f(a+h/2)| \leq Lh/2$. Para $f(x) = Lx$, la imagen del intervalo es $[La, La+Lh]$, de longitud Lh ; cualquier constante c dista al menos $Lh/2$ de uno de los dos extremos (si distara menos de $Lh/2$ de ambos, por la desigualdad triangular la longitud sería menor que Lh), y $c = La + Lh/2$ alcanza exactamente $Lh/2$. $\square$

Las dos proposiciones exhiben el compromiso de la técnica: intervalos estrechos reducen el sesgo de aproximación (Proposición 6.3), pero cada nivel $\bar{y}_k$ se estima con n_k datos y tiene varianza σ^2/n_k si los errores son homocedásticos con varianza σ^2 , que crece al estrechar los intervalos. Además, toda la información dentro de un intervalo se pierde: dos valores en el mismo intervalo reciben la misma predicción.

Robustez. La guía afirma que la discretización hace al modelo más robusto frente a atípicos y ruido. Con cortes por cuantiles, esto es exacto: cada corte $\hat{Q}(k/B)$ es un estadístico de orden de $\mathcal{D}_{\text{tr}}$, así que $b(x)$ depende de x solo a través de sus comparaciones con esos estadísticos de orden; un atípico, por extremo que sea, supera a todos y recibe la etiqueta B , la misma que cualquier valor apenas superior a $\hat{Q}((B-1)/B)$. Los propios cortes, por la Proposición 2.10, se mueven poco si se contamina una fracción pequeña de los datos. Además, por el Lema 5.2, la discretización por cuantiles es invariante a transformaciones estrictamente crecientes, lo que hace irrelevante tomar logaritmos antes. La discretización de ancho igual no tiene esta propiedad: un atípico estira el rango y vacía los intervalos intermedios.

Contraste. Frente a las transformaciones no lineales de la Sección 5, la discretización permite relaciones no monótonas pero pierde resolución y añade $B-1$ parámetros; frente a un árbol, que elige los cortes mirando la respuesta, los cortes aquí son no supervisados. El ejemplo de la guía (peso del vehículo en cinco categorías y después cinco indicadores) es exactamente la Definición 6.1 seguida de one-hot, y la Proposición 6.2 dice qué estima un modelo lineal con ellos. Los cortes por cuantiles se ajustan con $\mathcal{D}_{\text{tr}}$.

7. Codificación de variables categóricas

Motivación. Una variable categórica toma valores en un conjunto finito $\mathcal{C} = \{c_1, \dots, c_K\}$ sin estructura aritmética: no tiene sentido sumar “Rojo” y “Azul” ni, si es nominal, decir que uno es mayor que otro. Los algoritmos, en cambio, operan en $\mathbb{R}^p$. Codificar es elegir una función $\phi : \mathcal{C} \rightarrow \mathbb{R}^d$, y toda elección introduce en $\mathcal{C}$ la geometría de $\mathbb{R}^d$ (distancias, orden, combinaciones lineales). El problema es que esa geometría no debe inventar relaciones inexistentes ni consumir demasiadas dimensiones. Las cuatro codificaciones de la guía son cuatro compromisos distintos entre esas dos exigencias. En esta sección $K = |\mathcal{C}|$ es el número de categorías *distintas* (la *cardinalidad*); la guía llama a veces “categorías” a las observaciones, que pueden repetirse: en su ejemplo hay 10 observaciones de $K = 8$ colores.

7.1. Codificación por etiquetas u ordinal

Definición 7.1 (Codificación ordinal). Es una biyección $\phi : \mathcal{C} \rightarrow \{0, 1, \dots, K-1\}$, usada como una sola columna numérica.

La biyección induce un orden total y distancias $|\phi(c) - \phi(c')|$ en $\mathcal{C}$. `LabelEncoder` de scikit-learn elige el orden alfabético (en $\{\text{White}, \text{Black}, \text{Red}\}$ asigna $\text{Black} = 0$, $\text{Red} = 1$, $\text{White} = 2$), mientras que `OrdinalEncoder` con `categories` permite fijar el orden de una variable ordinal ($\text{Small} < \text{Medium} < \text{Large} < \text{X-Large}$). Las consecuencias de ese orden dependen del modelo.

Proposición 7.2 (Codificación ordinal en un modelo lineal). *Si la única representación de la categoría en un modelo lineal es la columna $\phi(c)$, las predicciones por categoría son $f(c) = \beta_0 + \beta_1 \phi(c)$. El vector de efectos $(f(c_1), \dots, f(c_K))$ pertenece al subespacio de dimensión 2 generado por $\mathbf{1}$ y $(\phi(c_1), \dots, \phi(c_K))$. Para $K \geq 3$ no todo vector de efectos es representable, y el conjunto de los representables depende de la biyección elegida.*

Demostración. El vector de efectos es $\beta_0 \mathbf{1} + \beta_1 (\phi(c_k))_k$, combinación lineal de dos vectores fijos, luego está en un subespacio de dimensión a lo sumo $2 < K$ y no puede ser todo $\mathbb{R}^K$. Para la dependencia de la biyección, sea $K = 3$ y sea $(0, \frac{1}{2}, 1)$ el vector de efectos de las categorías (c_1, c_2, c_3) . Con la codificación $\phi = (0, 1, 2)$ es representable, con $\beta_0 = 0$ y $\beta_1 = \frac{1}{2}$. Con la codificación $\phi = (1, 0, 2)$, que solo intercambia los códigos de c_1 y c_2 , se necesitaría $\beta_0 + \beta_1 = 0$, $\beta_0 = \frac{1}{2}$ y $\beta_0 + 2\beta_1 = 1$; las dos primeras dan $\beta_1 = -\frac{1}{2}$ y entonces $\beta_0 + 2\beta_1 = -\frac{1}{2} \neq 1$, así que no es representable. $\square$

Para una variable nominal, el orden alfabético no tiene relación con la respuesta, y el modelo lineal queda forzado a efectos equiespaciados en ese orden arbitrario; esta es la razón precisa de la advertencia de la guía (“Red sería el doble de Black”). Para una variable ordinal con efecto aproximadamente equiespaciado, la codificación ordinal es parsimoniosa: 2 parámetros en lugar de K .

Con árboles la situación es otra. Un corte sobre la columna ordinal separa $\mathcal{C}$ en $\{c : \phi(c) \leq t\}$ y su complemento.

Proposición 7.3 (Cortes de un árbol sobre una codificación ordinal). *(i) Un único corte produce a lo sumo $K-1$ biparticiones no triviales de $\mathcal{C}$, de las $2^{K-1} - 1$ posibles. (ii) Con a lo sumo dos cortes sucesivos se puede aislar cualquier categoría.*

Demostración. (i) Las biparticiones inducidas son $\{\phi \leq j\}$ frente a $\{\phi > j\}$ para $j = 0, \dots, K-2$, es decir, $K-1$. El total de biparticiones en dos partes no vacías se cuenta así: hay 2^K subconjuntos A , se excluyen $A = \emptyset$ y $A = \mathcal{C}$, y cada bipartición $\{A, A^c\}$ se contó dos veces, lo que da $(2^K - 2)/2 = 2^{K-1} - 1$. (ii) Para aislar la categoría de código j , el corte $\phi \leq j$ deja a un lado los códigos $\{0, \dots, j\}$ y, dentro de él, el corte $\phi \leq j-1$ separa $\{j\}$ (si $j = 0$ o $j = K-1$ basta un corte). $\square$

Así, un árbol puede representar cualquier efecto por categoría con la codificación ordinal, al precio de más cortes y de que las agrupaciones “naturales” que no son intervalos en el orden elegido requieren varios. Esa es la justificación de la regla de la guía (ordinal para árboles), que por la Proposición 4.3 tampoco depende de la escala de los códigos.

7.2. Codificación one-hot

Motivación. Las variables indicadoras (*dummy variables*) se introdujeron en la econometría de mediados del siglo XX para incluir factores cualitativos en regresiones sin imponerles orden. La idea es asignar a cada categoría su propio eje.

Definición 7.4 (Codificación one-hot). Es $\phi(c_k) = e_k \in \mathbb{R}^K$, el k -ésimo vector canónico.

Proposición 7.5 (Geometría y álgebra de one-hot). (i) $\langle e_k, e_l \rangle = \mathbf{1}[k = l]$ y $\|e_k - e_l\| = \sqrt{2}$ para $k \neq l$: todas las categorías son equidistantes. (ii) Un modelo lineal $f(c) = \gamma^\top \phi(c)$ puede representar cualquier vector de efectos en $\mathbb{R}^K$. (iii) Si además hay intercepto, las columnas de la matriz de diseño $[\mathbf{1}, D]$ son linealmente dependientes (“trampa de las variables ficticias”) y el estimador de mínimos cuadrados no es único. (iv) Si se elimina la columna de una categoría de referencia r , el ajuste por mínimos cuadrados con intercepto y las $K - 1$ restantes es único, sus valores ajustados son las medias por categoría y los coeficientes son $\hat{\beta}_0 = \bar{y}_r$ y $\hat{\beta}_k = \bar{y}_k - \bar{y}_r$.

Demostración. (i) El producto interno de vectores canónicos es la delta de Kronecker, y $\|e_k - e_l\|^2 = \|e_k\|^2 - 2\langle e_k, e_l \rangle + \|e_l\|^2 = 1 - 0 + 1 = 2$. (ii) $f(c_k) = \gamma^\top e_k = \gamma_k$, así que el vector de efectos es γ , arbitrario. (iii) Cada fila de D tiene un único 1, luego $\sum_k D_{.k} = \mathbf{1}$; la columna del intercepto es combinación lineal de las demás y se aplica la Proposición 3.5. (iv) El espacio columna de $[\mathbf{1}, D_{-r}]$ contiene $D_{.r} = \mathbf{1} - \sum_{k \neq r} D_{.k}$, luego coincide con el de D ; las K columnas de $[\mathbf{1}, D_{-r}]$ son independientes porque generan un espacio de dimensión K (el de D , cuyas columnas tienen soportes disjuntos no vacíos). Por la Proposición 6.2, los valores ajustados, que son la proyección sobre ese espacio común, son las medias por categoría. En un registro de la categoría r el valor ajustado es $\hat{\beta}_0$, luego $\hat{\beta}_0 = \bar{y}_r$; en uno de la categoría $k \neq r$ es $\hat{\beta}_0 + \hat{\beta}_k = \bar{y}_k$. $\square$

La parte (i) es la ventaja conceptual de one-hot para variables nominales: no inventa orden ni parecidos. La parte (ii) es su flexibilidad: con un modelo lineal equivale al modelo de medias por celda del análisis de varianza. Sus costos son la dimensión K (más de 40 000 columnas para los códigos postales de EE.UU., como señala la guía), el hecho de que las categorías raras tienen coeficientes estimados con muy pocos datos, y que una categoría nueva en producción no tiene columna (hay que decidir, por ejemplo, codificarla como el vector nulo). La matriz resultante es dispersa (una entrada no nula por fila y variable), lo que conecta con la Proposición 4.6(iv): si se escala, debe hacerse con MaxAbs o no hacerse.

7.3. Codificación binaria

Definición 7.6 (Codificación binaria). Se numeran las categorías con $\iota : \mathcal{C} \rightarrow \{1, \dots, K\}$ biyectiva y se representa $\iota(c)$ en base 2 con d dígitos: $\phi(c) = (b_{d-1}, \dots, b_0) \in \{0, 1\}^d$ con $\iota(c) = \sum_{s=0}^{d-1} b_s 2^s$, donde d es el menor entero con $2^d > K$.

La numeración empieza en 1 en `category_encoders` (en orden de aparición), lo que reserva el código $0 \dots 0$; por eso 8 categorías producen 4 columnas en el ejemplo de la guía y no 3.

Proposición 7.7 (Dimensión e inyectividad). (i) $d = \lfloor \log_2 K \rfloor + 1 = \lceil \log_2(K + 1) \rceil$. (ii) ϕ es inyectiva: la codificación no pierde información.

Demostración. (i) Sea d el entero con $2^{d-1} \leq K < 2^d$; es el menor con $2^d > K$ y cumple $d - 1 \leq \log_2 K < d$, luego $d = \lfloor \log_2 K \rfloor + 1$. De $K < 2^d$ se sigue $K + 1 \leq 2^d$, y de $2^{d-1} \leq K$ se sigue $K + 1 > 2^{d-1}$; así $d - 1 < \log_2(K + 1) \leq d$ y $d = \lceil \log_2(K + 1) \rceil$. (ii) Todo entero en $\{0, \dots, 2^d - 1\}$ tiene una única representación binaria con d dígitos (existencia por divisiones sucesivas entre 2; unicidad porque si dos representaciones distintas difieren por primera vez, desde arriba, en el dígito s , sus valores difieren al menos en $2^s - \sum_{t < s} 2^t = 1$). Como ι es biyectiva, ϕ es composición de inyectivas. $\square$

La guía afirma que la codificación binaria “puede provocar una pérdida de información”. Por (ii) no se pierde información en sentido estricto. Lo que ocurre es de otra naturaleza y depende del modelo.

Proposición 7.8 (Capacidad de un modelo lineal sobre bits). *Con un modelo lineal $f(c) = \beta_0 + \sum_s \beta_s b_s(c)$, los vectores de efectos representables forman un subespacio de $\mathbb{R}^K$ de dimensión a lo sumo $d+1$. Si $K > d+1$, lo que ocurre para todo $K \geq 5$, no todo vector de efectos es representable. Además, la distancia de Hamming entre códigos, $\#\{s : b_s(c) \neq b_s(c')\}$, varía entre 1 y d según la numeración, sin relación con las categorías.*

Demostración. La aplicación $(\beta_0, \dots, \beta_{d-1}) \mapsto (f(c_1), \dots, f(c_K))$ es lineal de $\mathbb{R}^{d+1}$ en $\mathbb{R}^K$, y su imagen tiene dimensión a lo sumo $d+1$. Por la Proposición 7.7, $d+1 \leq \log_2 K + 2$. La función $K \mapsto K - \log_2 K - 2$ vale $5 - \log_2 5 - 2 \approx 0.68 > 0$ en $K = 5$ y es creciente para $K \geq 2$ (su derivada es $1 - \frac{1}{K \ln 2} > 0$), así que $d+1 < K$ para todo $K \geq 5$ y la imagen es un subespacio propio. (En $K = 4$ se tiene $d = 3$ y $d+1 = K$.) En el ejemplo de la guía, $K = 8$ y $d+1 = 5$. Para las distancias: en el ejemplo, Red ($\iota = 3$, 0011) y Pink ($\iota = 7$, 0111) difieren en un bit, mientras que White ($\iota = 1$, 0001) y Brown ($\iota = 8$, 1000) difieren en dos; cambiar la numeración cambia estas distancias. $\square$

Esto es lo que la guía llama “difuminar las distinciones”: un modelo lineal o basado en distancias ve parecidos entre categorías que comparten bits y no puede asignar efectos arbitrarios. Un árbol, en cambio, puede aislar cualquier categoría fijando sus d bits con a lo sumo d cortes, porque cada corte sobre una columna binaria separa según un bit.

7.4. Hashing de características

Motivación. En aplicaciones de gran escala (filtros de spam personalizados, publicidad en línea), el número de categorías es enorme y crece con el tiempo: palabras, identificadores de usuario, combinaciones usuario–palabra. One-hot exige un diccionario $\mathcal{C} \rightarrow \{1, \dots, K\}$ que no cabe en memoria, que hay que reconstruir cuando aparecen categorías nuevas y cuya dimensión K no se conoce de antemano. Weinberger, Dasgupta, Langford, Smola y Attenberg (2009) formalizaron el “truco del hashing”: reemplazar el diccionario por una función fija que envía cada categoría a una de m columnas, aceptando colisiones, y mostraron que con un signo aleatorio los productos internos se conservan en esperanza.

Definición 7.9 (Mapa de hashing con signo). Sea $\mathcal{U}$ el universo de categorías (posiblemente infinito), $h : \mathcal{U} \rightarrow \{1, \dots, m\}$ y $\xi : \mathcal{U} \rightarrow \{-1, +1\}$. Para un vector $x \in \mathbb{R}^{\mathcal{U}}$ con finitas coordenadas no nulas (por ejemplo, conteos de palabras o el indicador de una categoría), el vector *hasheado* $\phi(x) \in \mathbb{R}^m$ es

$$\phi_j(x) = \sum_{i \in \mathcal{U} : h(i)=j} \xi(i) x_i, \quad j = 1, \dots, m.$$

Para una única categoría c ($x = e_c$), $\phi(e_c) = \xi(c) e_{h(c)}$. Dos categorías $c \neq c'$ *colisionan* si $h(c) = h(c')$.

En la implementación, h y ξ son funciones hash deterministas (**FeatureHasher** usa MurmurHash3: el índice sale del valor absoluto del hash módulo m y el signo, del signo de ese mismo valor). Para analizarlas se modelan como aleatorias: h uniforme e independiente por pares, y los $\xi(i)$ independientes, con $\mathbb{P}(\xi(i) = \pm 1) = \frac{1}{2}$ e independientes de h . Nada se ajusta con los datos, y por eso no hay diccionario que guardar ni riesgo de fuga en esta etapa.

¿Por qué el *feature hashing* tiene una forma tan fea?

La expresión

$$\phi_j(x) = \sum_{i : h(i)=j} \xi(i) x_i$$

parece más complicada de lo que realmente es. La idea básica empieza con una sola categoría $i \in \mathcal{U}$. La función hash

$$h : \mathcal{U} \rightarrow \{1, \dots, m\}$$

decide en qué coordenada del nuevo vector se almacenará esa categoría. Así, si e_i representa únicamente a la categoría i , el hashing con signo la transforma como

$$\phi(e_i) = \xi(i)e_{h(i)},$$

donde $\xi(i) \in \{-1, +1\}$. El valor $h(i)$ no se usa como magnitud numérica de la característica: solo indica la coordenada donde debe colocarse.

Para un vector general,

$$x = \sum_i x_i e_i,$$

se extiende la transformación linealmente:

$$\phi(x) = \sum_i x_i \phi(e_i) = \sum_i x_i \xi(i) e_{h(i)}.$$

Aquí aparece la suma: una observación puede contener muchas características activas y todas deben contribuir al vector hashado.

Además, distintas categorías pueden colisionar. Si, por ejemplo,

$$h(a) = h(c) = h(d) = 2,$$

entonces las tres contribuciones terminan en la misma coordenada:

$$\phi_2(x) = \xi(a)x_a + \xi(c)x_c + \xi(d)x_d.$$

En general, la coordenada j recoge precisamente las características cuyo hash vale j :

$$\phi_j(x) = \sum_{i: h(i)=j} \xi(i)x_i.$$

Por tanto,

$$h(i)$$

decide *dónde* cae la característica,

$$\xi(i)$$

decide con qué signo contribuye,

$$x_i$$

es su valor original, y la suma acumula todas las características que colisionaron en la misma coordenada.

Equivalentemente, el procedimiento es una transformación lineal

$$\phi(x) = Ax,$$

donde cada columna de A contiene un único elemento no nulo, $+1$ o -1 , situado en la fila indicada por $h(i)$.

En resumen,

“para la coordenada j , suma lo que el hash aventó ahí.”

La notación parece un desmadre; la operación subyacente es bastante simple.

Proposición 7.10 (Colisiones). Sean K categorías distintas. (i) Si $K > m$, hay al menos una colisión (principio del palomar). (ii) Bajo el modelo aleatorio, dos categorías fijas colisionan con probabilidad $1/m$, el número esperado de pares que colisionan es $\binom{K}{2}/m$ y, si h es además totalmente independiente, la probabilidad de no tener colisiones es $\prod_{i=1}^{K-1} (1 - i/m) \leq \exp(-\frac{K(K-1)}{2m})$.

Demostración. (i) K objetos en $m < K$ cajas no pueden quedar uno por caja. (ii) $\mathbb{P}(h(c) = h(c')) = \sum_j \mathbb{P}(h(c) = j) \mathbb{P}(h(c') = j) = m \cdot m^{-2} = 1/m$ por independencia por pares y uniformidad. El número de pares que colisionan es $\sum_{\{c, c'\}} \mathbf{1}[h(c) = h(c')]$ y, por linealidad de la esperanza, su media es $\binom{K}{2}/m$. Con independencia total, la probabilidad de que la categoría $i + 1$ evite las i cajas ya ocupadas por las anteriores (sin colisiones previas) es $1 - i/m$, y el producto de estas probabilidades condicionales da la probabilidad de ninguna colisión. Por $1 - t \leq e^{-t}$, el producto es $\leq \exp(-\sum_{i=1}^{K-1} i/m) = \exp(-K(K-1)/(2m))$. $\square$

En el ejemplo de la guía, $K = 8 > m = 3$ y las colisiones son inevitables; la salida real muestra White y Blue con el mismo vector, y Green, Pink y Brown también. Con $K = 10^4$ categorías y $m = 2^{20} \approx 10^6$ columnas, el número esperado de pares en colisión es $\binom{10^4}{2}/2^{20} \approx 47.7$: casi seguro hay alguna, pero afectan a una fracción ínfima de las categorías. El signo ξ hace que las colisiones no sesguen la geometría.

Teorema 7.11 (Weinberger et al.: insesgadez del producto interno). Bajo el modelo aleatorio, para $x, x' \in \mathbb{R}^U$ con soporte finito,

$$\mathbb{E}[\langle \phi(x), \phi(x') \rangle] = \langle x, x' \rangle, \quad \text{Var}(\langle \phi(x), \phi(x') \rangle) = \frac{1}{m} \sum_{i \neq j} (x_i^2 x_j'^2 + x_i x_i' x_j x_j').$$

Demostración. Escribimos $\delta_{ij} = \mathbf{1}[h(i) = h(j)]$. Desarrollando el producto interno de las sumas que definen ϕ ,

$$\langle \phi(x), \phi(x') \rangle = \sum_{j=1}^m \sum_{h(i)=j} \sum_{h(k)=j} \xi(i) \xi(k) x_i x_k' = \sum_{i,k} \xi(i) \xi(k) \delta_{ik} x_i x_k'.$$

Los términos con $i = k$ valen $\xi(i)^2 x_i x_i' = x_i x_i'$, porque $\xi(i)^2 = 1$ y $\delta_{ii} = 1$; su suma es $\langle x, x' \rangle$. Sea $S = \sum_{i \neq k} \xi(i) \xi(k) \delta_{ik} x_i x_k'$ el resto. Para $i \neq k$, $\mathbb{E}[\xi(i) \xi(k) \delta_{ik}] = \mathbb{E}[\xi(i)] \mathbb{E}[\xi(k)] \mathbb{E}[\delta_{ik}] = 0$ por independencia, así que $\mathbb{E}S = 0$ y el producto interno es insesgado.

Su varianza es $\mathbb{E}[S^2] = \sum_{i \neq k} \sum_{a \neq b} \mathbb{E}[\xi(i) \xi(k) \xi(a) \xi(b)] \mathbb{E}[\delta_{ik} \delta_{ab}] x_i x_k' x_a x_b'$. Como los ξ son independientes con media 0 y $\xi^2 = 1$, $\mathbb{E}[\xi(i) \xi(k) \xi(a) \xi(b)]$ es 1 si cada índice aparece un número par de veces y 0 en otro caso; con $i \neq k$ y $a \neq b$ esto ocurre exactamente cuando $(a, b) = (i, k)$ o $(a, b) = (k, i)$. En ambos casos $\mathbb{E}[\delta_{ik} \delta_{ab}] = \mathbb{E}[\delta_{ik}^2] = \mathbb{E}[\delta_{ik}] = 1/m$ (Proposición 7.10). Sumando las dos contribuciones, $\mathbb{E}[S^2] = \frac{1}{m} \sum_{i \neq k} (x_i x_k' x_i x_k' + x_i x_k' x_k x_i') = \frac{1}{m} \sum_{i \neq k} (x_i^2 x_k'^2 + x_i x_i' x_k x_k')$. $\square$

Para vectores unitarios la varianza es $O(1/m)$: el producto interno hashado se concentra en torno al verdadero al crecer m . Sin el signo ($\xi \equiv 1$), el término S tendría esperanza $\frac{1}{m} \sum_{i \neq k} x_i x_k'$, que para vectores de conteos no negativos es positiva: las colisiones harían parecer más similares a todos los pares. Para dos categorías distintas, $\langle \phi(e_c), \phi(e_{c'}) \rangle = \xi(c) \xi(c') \delta_{cc'}$ vale 0 si no colisionan y ± 1 con igual probabilidad si colisionan, con media 0 = $\langle e_c, e_{c'} \rangle$.

7.5. Contraste de las codificaciones

Codificación	Dimensión	Inyectiva	Diccionario	Geometría inducida y uso
Ordinal	1	sí	sí	orden y distancias arbitrarios si la variable es nominal (Prop. 7.2); adecuada para ordinales y para árboles (Prop. 7.3)
One-hot	K	sí	sí	equidistancia, efectos arbitrarios (Prop. 7.5); inviable con K muy grande; categorías nuevas sin columna
Binaria	$\lceil \log_2(K+1) \rceil$	sí	sí	parecidos artificiales por bits compartidos; capacidad lineal limitada (Prop. 7.8); adecuada para árboles
Hashing	m fija	no si $K > m$	no	colisiones indistinguibles; productos internos insesgados (Teo. 7.11); memoria fija, categorías nuevas sin reentrenar, no interpretable

La regla de la guía se deduce de la tabla: ordinal para variables ordinales y modelos de árboles; one-hot para cardinalidad pequeña y modelos no basados en árboles; binaria para reducir la dimensión de one-hot cuando el modelo tolera los parecidos artificiales; hashing para alta cardinalidad y recursos limitados. PCA después de one-hot, que la guía menciona como alternativa, reduce la dimensión pero, por el Teorema 3.7, conserva las direcciones de mayor varianza, que para indicadores son las de las categorías frecuentes, y pierde la interpretación por categoría.

8. Series de tiempo

Motivación. En una serie de tiempo $(y_t)_{t \in \mathbb{Z}}$ las observaciones no son intercambiables: y_t depende de $y_{t-1}, y_{t-2}, \dots$, y el orden es parte de la información. Un modelo tabular (regresión, árboles, redes) no sabe nada de ese orden; para que lo aproveche hay que escribir el pasado como columnas. Al mismo tiempo, el orden introduce una restricción nueva que no existe en datos i.i.d.: al predecir y_t solo puede usarse lo que se conocía antes de t . Las técnicas de la guía (descomponer la fecha, codificarla, rezagos y ventanas móviles) son formas de construir columnas que respeten esa restricción.

Definición 8.1 (Característica admisible). Sea $\mathcal{I}_t$ la información disponible al final del instante t : los valores y_s y las covariables w_s con $s \leq t$, más las funciones deterministas del calendario (fecha, día de la semana, feriados), que se conocen de antemano. Una característica para predecir y_t con horizonte 1 es *admisible* si es función de $\mathcal{I}_{t-1}$. Toda característica no admisible es fuga del objetivo.

La definición convierte la advertencia de la guía (“un rezago solo puede usar valores anteriores al momento de la predicción”) en un criterio verificable columna por columna. Es la misma condición que garantizan las consultas *point-in-time* de Feature Store: el valor de una característica para un evento con marca de tiempo t se toma del último registro con marca $\leq t$.

8.1. Descomposición de la fecha y codificación cíclica

Las características de calendario (mes, día del mes, semana del año, día del año, trimestre, día de la semana) son funciones deterministas de la marca de tiempo y, por la Definición 8.1, siempre

admisibles. Su utilidad es permitir que el modelo capture patrones periódicos; su dificultad es que son periódicas, y ninguna codificación en una recta representa bien un ciclo.

Definición 8.2 (Codificación cíclica). Para una característica periódica $m \in \{0, 1, \dots, P-1\}$ de periodo P (mes con $P = 12$ numerado desde 0, hora con $P = 24$, día de la semana con $P = 7$), la *codificación cíclica* es $\psi(m) = (\cos \frac{2\pi m}{P}, \sin \frac{2\pi m}{P}) \in \mathbb{R}^2$.

La codificación coloca los P valores en los vértices de un polígono regular inscrito en la circunferencia unidad. La propiedad que se busca es que la distancia entre dos valores dependa solo de cuántos pasos los separan en el ciclo.

Proposición 8.3 (Distancia circular). Sea $d_P(m, m') = \min(|m - m'|, P - |m - m'|)$ la *distancia circular*. Entonces

$$\|\psi(m) - \psi(m')\| = 2 \sin\left(\frac{\pi d_P(m, m')}{P}\right),$$

que es una función estrictamente creciente de $d_P(m, m') \in \{0, \dots, \lfloor P/2 \rfloor\}$. En cambio, con la *codificación ordinal* $m \mapsto m$, la distancia es $|m - m'|$.

Demostración. Sea $\alpha = 2\pi(m - m')/P$. Por la identidad $\cos a \cos b + \sin a \sin b = \cos(a - b)$,

$$\|\psi(m) - \psi(m')\|^2 = 2 - 2\left(\cos \frac{2\pi m}{P} \cos \frac{2\pi m'}{P} + \sin \frac{2\pi m}{P} \sin \frac{2\pi m'}{P}\right) = 2 - 2 \cos \alpha = 4 \sin^2 \frac{\alpha}{2},$$

usando $1 - \cos \alpha = 2 \sin^2(\alpha/2)$. Entonces $\|\psi(m) - \psi(m')\| = 2 |\sin(\pi(m - m')/P)|$. La función $k \mapsto |\sin(\pi k/P)|$ es par y cumple $|\sin(\pi(P - k)/P)| = |\sin(\pi - \pi k/P)| = |\sin(\pi k/P)|$, así que su valor en $k = |m - m'|$ coincide con su valor en $d_P(m, m')$. Para $d \in [0, P/2]$ el argumento $\pi d/P$ está en $[0, \pi/2]$, donde el seno es no negativo y estrictamente creciente. $\square$

Con meses numerados 0 (enero) a 11 (diciembre), la codificación ordinal pone a diciembre y enero a distancia 11, la máxima, cuando en el ciclo son vecinos; la cíclica les da la distancia $2 \sin(\pi/12) \approx 0.518$, la misma que a enero y febrero. Un segundo argumento, para modelos lineales, muestra qué forma de efecto estacional permite la codificación.

Proposición 8.4 (Efecto lineal de la codificación cíclica). Un modelo lineal $f(m) = \beta_0 + a \cos \frac{2\pi m}{P} + b \sin \frac{2\pi m}{P}$ es exactamente una senoide de periodo P con amplitud y fase arbitrarias: $f(m) = \beta_0 + A \cos(\frac{2\pi m}{P} - \varphi)$ con $A = \sqrt{a^2 + b^2}$ y $(\cos \varphi, \sin \varphi) = (a, b)/A$ si $A > 0$.

Demostración. Por la fórmula del coseno de una diferencia, $A \cos(\theta - \varphi) = A \cos \varphi \cos \theta + A \sin \varphi \sin \theta = a \cos \theta + b \sin \theta$ con $\theta = 2\pi m/P$. $\square$

Contraste. La codificación cíclica usa 2 columnas y fuerza un efecto sinusoidal suave con un solo máximo en el ciclo; la codificación one-hot del mes (o del trimestre, como sugiere la guía) usa P columnas y, por la Proposición 7.5, permite cualquier perfil estacional, a costa de estimar P parámetros; la ordinal usa 1 columna e introduce la discontinuidad diciembre-enero. Esto explica la recomendación de Data Wrangler: codificación cíclica para modelos lineales y redes, ordinal para árboles, a los que la discontinuidad no afecta porque pueden cortar en cualquier punto (Proposición 7.3). Si hace falta un perfil más rico que una senoide, se añaden armónicos $\cos \frac{2\pi km}{P}, \sin \frac{2\pi km}{P}$ para $k = 2, 3, \dots$, que es un desarrollo de Fourier del efecto estacional.

8.2. Rezagos y autocorrelación

Definición 8.5 (Rezago y autocorrelación). La característica de *rezago* $k \geq 1$ para predecir y_t es y_{t-k} ; un rezago *estacional* es y_{t-s} con s el periodo (por ejemplo, la misma hora del día anterior, $s = 24$). Si (y_t) es estacionaria en sentido débil (media μ y covarianzas $\gamma(h) = \text{Cov}(y_t, y_{t-h})$ que no dependen de t), su *función de autocorrelación* es $\rho(h) = \gamma(h)/\gamma(0)$.

Los rezagos son admisibles por construcción, porque $y_{t-k} \in \mathcal{I}_{t-1}$. La autocorrelación mide cuánto informa cada rezago de forma lineal, como muestra el resultado siguiente.

Proposición 8.6 (Mejor predictor lineal con un rezago). Si (y_t) es estacionaria débil con media 0 y $\gamma(0) > 0$, entonces $\mathbb{E}[(y_t - ay_{t-k})^2]$ se minimiza en $a = \rho(k)$, con valor mínimo $\gamma(0)(1 - \rho(k)^2)$.

Demostración. Desarrollando, $\mathbb{E}[(y_t - ay_{t-k})^2] = \gamma(0) - 2a\gamma(k) + a^2\gamma(0)$, una parábola en a con coeficiente principal $\gamma(0) > 0$, minimizada en $a = \gamma(k)/\gamma(0) = \rho(k)$. Sustituyendo, el valor es $\gamma(0) - 2\gamma(k)^2/\gamma(0) + \gamma(k)^2/\gamma(0) = \gamma(0)(1 - \rho(k)^2)$. $\square$

Así, la fracción de varianza que un rezago explica linealmente es $\rho(k)^2$, y los rezagos útiles se identifican en el gráfico de autocorrelación. En el modelo más simple la estructura es explícita.

Ejemplo 8.7 (Proceso AR(1)). Sea $y_t = \phi y_{t-1} + \varepsilon_t$ con $|\phi| < 1$ y ε_t i.i.d. de media 0 y varianza σ^2 , independientes del pasado $y_{t-1}, y_{t-2}, \dots$, y supongamos la solución estacionaria. Para $h \geq 1$, $\gamma(h) = \text{Cov}(\phi y_{t-1} + \varepsilon_t, y_{t-h}) = \phi\gamma(h-1) + 0$, porque ε_t es independiente de y_{t-h} . Iterando, $\gamma(h) = \phi^h\gamma(0)$ y $\rho(h) = \phi^h$. De $\gamma(0) = \text{Var}(\phi y_{t-1} + \varepsilon_t) = \phi^2\gamma(0) + \sigma^2$ se obtiene $\gamma(0) = \sigma^2/(1 - \phi^2)$. El residuo de predecir con el primer rezago, $y_t - \phi y_{t-1} = \varepsilon_t$, es independiente de todo el pasado, así que ningún rezago adicional mejora el predictor lineal: aunque $\rho(2) = \phi^2 \neq 0$, la información del rezago 2 ya está contenida en el rezago 1. La autocorrelación *parcial* es la herramienta que distingue esta situación.

Fuga en rezagos. Un rezago mal alineado ($k = 0$) usa el propio y_t y produce un ajuste perfecto que no existe en producción. Lo mismo ocurre, de forma más sutil, con estadísticas calculadas en ventanas centradas o con toda la serie (una media global, una normalización con el máximo de toda la serie), porque incluyen valores posteriores a t y violan la Definición 8.1.

8.3. Ventanas móviles

Definición 8.8 (Estadísticas de ventana móvil). Para una ventana de tamaño w , las características de ventana móvil de y_t son estadísticas de $(y_{t-w}, \dots, y_{t-1})$: la media $\bar{y}_t^{(w)} = \frac{1}{w} \sum_{k=1}^w y_{t-k}$, el mínimo, el máximo, la desviación estándar, etc.

La ventana termina en $t-1$ para que la característica sea admisible (con $w = 3$, la fila t recibe estadísticas de $t-3, t-2, t-1$, como describe la guía). El tamaño w regula un compromiso entre ruido y retraso.

Proposición 8.9 (Compromiso de la media móvil). (i) Si $y_t = \mu + \varepsilon_t$ con ε_t incorrelacionados de varianza σ^2 , entonces $\mathbb{E}\bar{y}_t^{(w)} = \mu$ y $\text{Var}\bar{y}_t^{(w)} = \sigma^2/w$. (ii) Si $y_t = a + bt$ (tendencia lineal sin ruido), entonces $\bar{y}_t^{(w)} = y_t - b \frac{w+1}{2}$: la media móvil va retrasada $\frac{w+1}{2}$ periodos.

Demostración. (i) Por linealidad, $\mathbb{E}\bar{y}_t^{(w)} = \mu$, y por incorrelación $\text{Var}\bar{y}_t^{(w)} = w^{-2} \sum_{k=1}^w \text{Var}\varepsilon_{t-k} = \sigma^2/w$. (ii) $\bar{y}_t^{(w)} = a + \frac{b}{w} \sum_{k=1}^w (t-k) = a + bt - \frac{b}{w} \cdot \frac{w(w+1)}{2} = y_t - b \frac{w+1}{2}$. $\square$

Ventanas grandes reducen el ruido en proporción $1/w$ pero reaccionan tarde a cambios de nivel; ventanas pequeñas siguen los cambios pero son ruidosas. Por eso es habitual incluir varias ventanas a la vez. La extracción automática (Data Wrangler ofrece *Rolling window features* y *Extract features*) calcula muchas estadísticas de este tipo y deja al modelo o a una selección posterior (Sección 3.1) decidir cuáles sirven.

9. Imágenes

Una imagen en color de $H \times W$ píxeles es un tensor $I \in \{0, \dots, 255\}^{H \times W \times 3}$ (intensidades de 8 bits por canal). Vista como vector de características, su dimensión es $3HW$: con 224×224 son 150 528 coordenadas, como calcula la guía. La maldición de la dimensionalidad (Sección 3) y el hecho de que el significado de una imagen no cambia si el objeto se desplaza unos píxeles hacen que los píxeles crudos sean malas características para modelos genéricos. La historia de la visión por computadora es la de la búsqueda de mejores mapas ϕ .

9.1. Normalización de píxeles

La normalización habitual $I \mapsto I/255$ es un escalado MinMax con rango *conocido de antemano* $[0, 255]$, no estimado: no es una transformación ajustada en el sentido de la Definición 1.2, no depende de los datos, no tiene fuga y no sufre el problema de atípicos de la Proposición 4.6(ii), porque ningún píxel puede superar 255. La estandarización por canal, $(I_{\cdot c}/255 - \mu_c)/\sigma_c$, sí usa parámetros; cuando se usa una red preentrenada, μ_c y σ_c deben ser los del conjunto con que se preentrenó, para que las entradas estén en la escala que la red espera (la misma lógica que la Definición 1.3: los parámetros de la transformación los fija el entrenamiento).

9.2. Características diseñadas a mano: bordes

Antes de las redes neuronales, las características se diseñaban: detectores de bordes, histogramas de color y de gradientes, o indicadores de partes (el `windshield_present` de la guía). El ejemplo más simple muestra la idea matemática. Un borde es un lugar donde la intensidad cambia rápido, es decir, donde el gradiente de la imagen, vista como función $f(u, v)$ muestreada, es grande. La derivada se aproxima con diferencias.

Proposición 9.1 (Diferencia central). *Si $f \in C^3$ en un entorno de u , entonces*

$$\frac{f(u+h) - f(u-h)}{2h} = f'(u) + \frac{h^2}{12}(f'''(\xi_+) + f'''(\xi_-))$$

para ciertos $\xi_{\pm}$ entre $u-h$ y $u+h$; en particular, el error es $O(h^2)$.

Demostración. Por el teorema de Taylor con resto de Lagrange, $f(u \pm h) = f(u) \pm hf'(u) + \frac{h^2}{2}f''(u) \pm \frac{h^3}{6}f'''(\xi_{\pm})$. Restando, los términos de orden 0 y 2 se cancelan: $f(u+h) - f(u-h) = 2hf'(u) + \frac{h^3}{6}(f'''(\xi_+) + f'''(\xi_-))$. Dividiendo entre $2h$ se obtiene la fórmula. $\square$

El filtro de Sobel (1968) aplica esta diferencia en una dirección y promedia en la perpendicular para reducir ruido. Su núcleo es el producto exterior

$$S_u = \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix} \begin{pmatrix} -1 & 0 & 1 \end{pmatrix} = \begin{pmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{pmatrix},$$

es decir, una diferencia central (sin el factor $\frac{1}{2h}$) en la dirección horizontal compuesta con un suavizado $(1, 2, 1)$ en la vertical. La magnitud $\sqrt{(S_u * I)^2 + (S_v * I)^2}$ es una imagen de bordes. El inconveniente de este enfoque es que cada característica útil para un problema nuevo (parabrisas, faros) debe diseñarse a mano.

9.3. Convolución y redes convolucionales

Motivación. Una red totalmente conectada que reciba los 150 528 píxeles y tenga una primera capa de 1000 neuronas necesita $150\,528 \times 1000 + 1000 \approx 1.5 \times 10^8$ parámetros, y no sabe que un gato desplazado sigue siendo un gato: cada posición tiene sus propios pesos. LeCun y colaboradores (1989) resolvieron ambos problemas imponiendo que la primera capa aplique el mismo filtro pequeño en todas las posiciones, como el filtro de Sobel, pero con los pesos aprendidos.

Definición 9.2 (Convolución discreta). Sea $I : \mathbb{Z}_H \times \mathbb{Z}_W \rightarrow \mathbb{R}$ una imagen de un canal con índices módulo H y W (relleno circular) y k un núcleo con soporte en $\{-r, \dots, r\}^2$. La convolución (en la convención de las redes neuronales, que no invierte el núcleo) es

$$(k * I)(u, v) = \sum_{a=-r}^r \sum_{b=-r}^r k(a, b) I(u + a, v + b).$$

El operador de traslación es $(\tau_{s,t}I)(u, v) = I(u - s, v - t)$.

Teorema 9.3 (Equivariancia por traslaciones). *Para todo núcleo k y toda traslación, $k * (\tau_{s,t}I) = \tau_{s,t}(k * I)$.*

Demostración. Para cada (u, v) ,

$$(k * (\tau_{s,t}I))(u, v) = \sum_{a,b} k(a, b) I(u + a - s, v + b - t) = (k * I)(u - s, v - t) = (\tau_{s,t}(k * I))(u, v),$$

donde la segunda igualdad es la definición de $(k * I)$ evaluada en $(u - s, v - t)$. $\square$

Corolario 9.4 (Invariancia tras promedio global). *Sea $\Phi(I) = \frac{1}{HW} \sum_{u,v} \sigma((k * I)(u, v))$ con $\sigma : \mathbb{R} \rightarrow \mathbb{R}$ cualquier función (una activación). Entonces $\Phi(\tau_{s,t}I) = \Phi(I)$.*

Demostración. Por el Teorema 9.3, $\sigma((k * \tau_{s,t}I)(u, v)) = \sigma((k * I)(u - s, v - t))$. Al sumar sobre todos los $(u, v) \in \mathbb{Z}_H \times \mathbb{Z}_W$, el cambio de índices $(u, v) \mapsto (u - s, v - t)$ es una biyección del grupo cíclico, así que la suma no cambia. $\square$

La convolución también resuelve el problema de parámetros: una capa con núcleos 3×3 de 3 canales de entrada a 64 de salida tiene $3 \cdot 3 \cdot 3 \cdot 64 + 64 = 1792$ parámetros, independientemente del tamaño de la imagen. Una red convolucional compone capas de convolución, activaciones no lineales y reducciones espaciales (*pooling*); por el Teorema 9.3 cada capa convolutiva es equivariante, y un promedio global al final produce, como en el Corolario 9.4, características invariantes a traslaciones (exactamente, con relleno circular y sin reducciones intermedias; aproximadamente, en las arquitecturas reales).

Las características que extrae la red. Si $N = g \circ \Phi$ es una red entrenada para clasificar, con g la última capa (lineal seguida de softmax) y Φ todo lo anterior, el vector $\Phi(I) \in \mathbb{R}^d$ (con d del orden de 10^2 a 10^3) es el *vector de características* o *embedding* de la imagen. El entrenamiento obligó a que las clases fueran separables linealmente en ese espacio, porque g es lineal; por eso $\Phi(I)$ suele servir como entrada tabular para otros problemas (*aprendizaje por transferencia*): se ajusta solo un

modelo sencillo sobre $\Phi(I)$ con pocos datos etiquetados. Es lo que la guía describe con los modelos preentrenados de SageMaker JumpStart. Frente al diseño manual (Sobel, indicadores de partes), las características aprendidas no requieren conocimiento del dominio para cada problema, pero no son interpretables y exigen una red preentrenada en imágenes parecidas.

Reducción de dimensión. La guía menciona también reducir la resolución y aplicar PCA. Promediar bloques de 2×2 píxeles divide la dimensión entre 4 y es un caso de convolución (núcleo constante $\frac{1}{4}$) seguida de submuestreo; PCA sobre píxeles o sobre embeddings sigue el Teorema 3.7 y requiere, como siempre, ajustarse con $\mathcal{D}_{\text{tr}}$. Las salidas de un servicio de visión (etiquetas con su confianza, cuadros delimitadores dados por coordenadas normalizadas $(x_0, y_0, \text{ancho}, \text{alto}) \in [0, 1]^4$) son características tabulares directas, a partir de las cuales se derivan otras, como el área relativa ancho $\times$ alto o el número de objetos de cada clase.

10. Texto

Motivación. Un documento es una cadena de caracteres de longitud variable; un modelo necesita un vector de dimensión fija. El camino que la guía recorre (tokenizar, eliminar palabras vacías, reducir a raíces, formar n-gramas y, finalmente, usar embeddings) reproduce la historia del procesamiento de lenguaje natural: primero representaciones de conteo, dispersas y sin noción de significado, después representaciones densas aprendidas que sí la tienen. Cada paso responde a una limitación demostrable del anterior.

10.1. Tokenización y bolsa de palabras

Definición 10.1 (Tokenización, vocabulario y bolsa de palabras). Una *tokenización* es una función τ que asigna a cada documento d una sucesión finita de *tokens* $\tau(d) = (t_1, \dots, t_L)$ en un conjunto V , el *vocabulario*. La *bolsa de palabras* de d es el vector de conteos $x(d) \in \mathbb{N}^V$ con $x_v(d) = \#\{\ell : t_\ell = v\}$.

El vocabulario es un parámetro ajustado: se construye con $\mathcal{D}_{\text{tr}}$, y una palabra que aparezca por primera vez en producción no tiene coordenada (salvo que se use hashing, Sección 7.4, que es exactamente la solución que `HashingVectorizer` aplica a texto). La bolsa de palabras aplicada a un documento de una sola palabra es la codificación one-hot de esa palabra (Definición 7.4), y hereda sus dos problemas: dimensión $|V|$ (decenas o cientos de miles) y ausencia de noción de parecido. Tiene además uno propio.

Proposición 10.2 (La bolsa de palabras ignora el orden). Si $\tau(d')$ es una permutación de $\tau(d)$, entonces $x(d) = x(d')$.

Demostración. x_v cuenta las posiciones con token v , y una permutación biyectiva de las posiciones conserva ese número para cada v . $\square$

“Dog bites man” y “man bites dog” tienen la misma bolsa de palabras y significados opuestos. Los n-gramas (Sección 10.3) recuperan parte del orden.

10.2. Palabras vacías, ponderación TF-IDF y reducción a raíces

La eliminación de palabras vacías con una lista $S \subset V$ es la proyección que anula las coordenadas de S : $x \mapsto (x_v \mathbf{1}[v \notin S])_{v \in V}$. Reduce la dimensión en $|S|$ y, en tareas de tópicos, quita coordenadas de mucha varianza y poca información. Pero es una decisión fija e independiente de la tarea, y puede destruir información esencial: si S contiene “not”, los documentos “not good” y “good” quedan con

la misma representación, y en análisis de sentimiento eso invierte el significado. La guía lo advierte con su “a menudo”.

Existe una alternativa que decide con los datos cuánto pesa cada palabra. Spärck Jones (1972) observó que una palabra que aparece en casi todos los documentos no sirve para distinguirlos, y propuso ponderar por la rareza.

Definición 10.3 (TF-IDF). Para una colección de N documentos, sea $\text{df}(v)$ el número de documentos que contienen v . La *frecuencia inversa en documentos* es $\text{idf}(v) = \log \frac{N}{\text{df}(v)}$ y el peso TF-IDF de v en d es $x_v(d) \text{idf}(v)$.

Como $1 \leq \text{df}(v) \leq N$, se tiene $0 \leq \text{idf}(v) \leq \log N$; idf es decreciente en df y vale exactamente 0 para una palabra presente en todos los documentos, porque $\log(N/N) = 0$. Así, las palabras vacías más extremas se anulan solas, sin lista, y las intermedias se atenúan en lugar de eliminarse. La transformación *Vectorize* de Data Wrangler produce vectores TF-IDF. Los $\text{df}(v)$ son parámetros ajustados con $\mathcal{D}_{\text{tr}}$. (Las implementaciones usan variantes suavizadas, como $\log \frac{1+N}{1+\text{df}(v)} + 1$ en scikit-learn, que evitan divisiones por cero y no anulan del todo el peso.)

El *stemming* y la *lematización* son funciones $\pi : V \rightarrow V'$ que envían cada palabra a una forma base; la bolsa de palabras reducida es $x'_{v'} = \sum_{v:\pi(v)=v'} x_v$. Matemáticamente es la misma operación que el hashing: una aplicación lineal de $\mathbb{R}^V$ en $\mathbb{R}^{V'}$ que suma coordenadas que “colisionan”. La diferencia es que aquí las colisiones se eligen para que sean deseables (“running”, “runs” $\mapsto$ “run”), mientras que en el hashing son aleatorias. El stemming usa reglas de recorte de sufijos (Porter, 1980), rápidas pero con dos tipos de error: *sobrerreducción*, que une palabras distintas (“universe” y “university” $\mapsto$ “univers”), y *subreducción*, que no une formas de la misma palabra (“ran” y “run” quedan separados, porque la relación no es un sufijo). La lematización consulta un diccionario y la categoría gramatical (“better” como adjetivo $\mapsto$ “good”), con menos errores de ambos tipos y más costo. Ambas reducen $|V'| \leq |V|$ y agrupan conteos, lo que mejora la estimación de palabras raras; ambas pierden información morfológica (tiempo verbal, número) que en algunas tareas importa.

10.3. N-gramas

Definición 10.4 (N-gramas). Para $\tau(d) = (t_1, \dots, t_L)$ y $n \leq L$, los *n-gramas* de d son las $L - n + 1$ subsucesiones contiguas $(t_\ell, \dots, t_{\ell+n-1})$, $\ell = 1, \dots, L - n + 1$. La bolsa de n-gramas cuenta sus apariciones en V^n .

En “Machine learning is fun” ($L = 4$) hay $4 - 2 + 1 = 3$ bigramas, como en la guía. Los bigramas separan los ejemplos de la Proposición 10.2: “dog bites man” contiene (dog, bites) y “man bites dog” no; también capturan “not good” como unidad. El costo es combinatorio: el espacio de n-gramas posibles tiene $|V|^n$ elementos, y aunque solo aparece una fracción, la cantidad observada crece rápidamente con n y cada n-grama se observa pocas veces, lo que vuelve a la maldición de la dimensionalidad. En la práctica se usan $n \leq 3$, a menudo con hashing o con un umbral de frecuencia mínima.

10.4. Embeddings de palabras

Motivación. Todas las representaciones anteriores tratan las palabras como símbolos sin relación entre sí, como muestra el resultado siguiente, que es la Proposición 7.5(i) en este contexto.

Proposición 10.5 (Ortogonalidad de las representaciones de conteo). *Con la codificación one-hot de palabras, la similitud coseno $\cos(e_v, e_{v'}) = \langle e_v, e_{v'} \rangle / (\|e_v\| \|e_{v'}\|)$ vale 0 para todo $v \neq v'$.*

Demostración. $\langle e_v, e_{v'} \rangle = 0$ y $\|e_v\| = \|e_{v'}\| = 1$. $\square$

“King” está tan lejos de “queen” como de “banana”, y lo aprendido sobre una palabra no se transfiere a sus sinónimos. La *hipótesis distribucional* (Harris, 1954; Firth, 1957: una palabra se caracteriza por las palabras que la acompañan) sugiere representar cada palabra por sus contextos. Los embeddings son vectores densos $v_w \in \mathbb{R}^D$ con D del orden de 10^2 , aprendidos para que palabras con contextos parecidos tengan vectores cercanos.

Word2Vec (Mikolov et al., 2013). En la variante *skip-gram*, cada palabra w tiene un vector v_w y cada palabra de contexto c un vector u_c , y se modela $p(c | w) = \exp(u_c^\top v_w) / \sum_{c' \in V} \exp(u_{c'}^\top v_w)$, maximizando $\sum \log p(c | w)$ sobre los pares (palabra, contexto) observados en ventanas del corpus. El denominador suma sobre todo el vocabulario, lo que hace cada paso de costo $O(|V|)$; el *muestreo negativo* (SGNS) lo reemplaza por un problema de clasificación binaria: distinguir pares observados de k pares (w, c_N) con c_N muestreado de la distribución unigrama $P(c) = \#(c) / |\mathcal{D}|$, donde $\#(\cdot)$ son conteos y $|\mathcal{D}|$ el número total de pares. Levy y Goldberg (2014) mostraron qué calcula realmente este procedimiento.

Teorema 10.6 (SGNS factoriza la información mutua puntual desplazada). *Sea $\sigma(x) = 1/(1+e^{-x})$. El objetivo esperado de SGNS para un par (w, c) , como función de $x = u_c^\top v_w$, es*

$$\ell_{wc}(x) = \#(w, c) \log \sigma(x) + k \frac{\#(w)\#(c)}{|\mathcal{D}|} \log \sigma(-x).$$

Si $\#(w, c) > 0$, ℓ_{wc} es estrictamente cóncava y se maximiza en

$$x^* = \log \frac{\#(w, c) |\mathcal{D}|}{\#(w) \#(c)} - \log k = \text{PMI}(w, c) - \log k.$$

En consecuencia, si la dimensión D es suficiente para que los productos $u_c^\top v_w$ puedan elegirse libremente, el óptimo global cumple $u_c^\top v_w = \text{PMI}(w, c) - \log k$ para todos los pares.

Demostración. El primer término suma $\log \sigma(u_c^\top v_w)$ sobre las $\#(w, c)$ apariciones del par. El segundo es la esperanza de la contribución de los negativos: la palabra w aparece $\#(w)$ veces, en cada una se muestrean k contextos negativos, y cada uno es c con probabilidad $\#(c) / |\mathcal{D}|$; cada vez que sale c se suma $\log \sigma(-u_c^\top v_w)$. Esto justifica la forma de ℓ_{wc} .

De $\sigma(x) = 1/(1+e^{-x})$ se obtiene $\frac{d}{dx} \log \sigma(x) = \frac{e^{-x}}{1+e^{-x}} = \sigma(-x)$ y, por la regla de la cadena, $\frac{d}{dx} \log \sigma(-x) = -\sigma(x)$. Con $B = k\#(w)\#(c) / |\mathcal{D}| > 0$,

$$\ell'_{wc}(x) = \#(w, c) \sigma(-x) - B \sigma(x), \quad \ell''_{wc}(x) = -(\#(w, c) + B) \sigma(x) \sigma(-x) < 0,$$

usando $\sigma'(x) = \sigma(x) \sigma(-x)$. La concavidad estricta garantiza que un punto crítico es el máximo único. La condición $\ell'_{wc}(x) = 0$ equivale a $\sigma(x) / \sigma(-x) = \#(w, c) / B$, y $\sigma(x) / \sigma(-x) = \frac{1+e^x}{1+e^{-x}} = e^x$. Luego $x^* = \log \frac{\#(w, c)}{B} = \log \frac{\#(w, c) |\mathcal{D}|}{k \#(w) \#(c)}$, que es la expresión enunciada. Si los productos pueden elegirse de forma independiente para cada par, el objetivo total, que es la suma de los ℓ_{wc} , se maximiza maximizando cada sumando. $\square$

La cantidad $\text{PMI}(w, c) = \log \frac{\hat{p}(w, c)}{\hat{p}(w) \hat{p}(c)}$ es la información mutua puntual empírica: el sumando de la información mutua de la Definición 3.2. El teorema dice que los embeddings de Word2Vec son una factorización de rango bajo de la matriz de PMI desplazada: dos palabras w, w' con filas de PMI parecidas (contextos parecidos) reciben vectores $v_w, v_{w'}$ con productos parecidos contra todos los contextos, que es la formalización de la hipótesis distribucional.

GloVe (Pennington, Socher y Manning, 2014) parte directamente de la matriz de coocurrencias X_{ij} y minimiza el error cuadrático ponderado

$$J = \sum_{i,j: X_{ij} > 0} f(X_{ij})(w_i^\top \tilde{w}_j + b_i + \tilde{b}_j - \log X_{ij})^2, \quad f(x) = \min(1, (x/x_{\max})^\alpha),$$

con $\alpha = 3/4$ en el artículo original. El peso f evita que los pares muy frecuentes dominen y anula los pares no observados. Si los sesgos toman los valores $b_i = \log X_{i.}$ y $\tilde{b}_j = \log X_{.j} - \log X_{..}$ (con $X_{i.}, X_{.j}, X_{..}$ las sumas por fila, columna y total), un ajuste exacto daría $w_i^\top \tilde{w}_j = \log X_{ij} - \log X_{i.} - \log X_{.j} + \log X_{..} = \text{PMI}(i, j)$. Las dos técnicas, presentadas en la guía como “red pequeña” y “factorización”, aproximan por tanto el mismo objeto; difieren en la función de pérdida y en el peso que dan a cada par.

Contraste de representaciones de texto.

Representación	Dimensión	Ventajas y limitaciones
Bolsa de palabras	$ V $, dispersa	simple, interpretable; ignora orden (Prop. 10.2) y similitud (Prop. 10.5)
Palabras vacías / raíces	$\leq V $	reducen dimensión agrupando o quitando coordenadas; errores de sobre y subreducción; pueden quitar negaciones
TF-IDF	$ V $, dispersa	pondera por rareza con los datos; mismas limitaciones de orden y similitud
N-gramas	hasta $ V ^n$	recuperan orden local; explosión combinatoria
Embeddings	$D \approx 10^2$, densa	similitud semántica (Teo. 10.6); requieren corpus grande; un vector por palabra aunque tenga varios sentidos; palabras nuevas sin vector

10.5. Tokenización en modelos fundacionales

Los modelos fundacionales no tokenizan por palabras completas sino por *subpalabras*. El algoritmo BPE (*byte pair encoding*, adaptado a NLP por Sennrich, Haddow y Birch, 2016) parte de los caracteres y repite: contar los pares de símbolos adyacentes más frecuentes en el corpus y fusionar el más frecuente en un símbolo nuevo, hasta alcanzar un tamaño de vocabulario prefijado. Resuelve el problema de las palabras nuevas de los embeddings de palabra: toda cadena se puede escribir con los símbolos iniciales, así que ninguna queda fuera del vocabulario; las palabras frecuentes son un token y las raras se parten en varios. Por eso el número de tokens de un texto no es su número de palabras (la regla aproximada de la guía, un token $\approx \frac{3}{4}$ de palabra en inglés, depende del tokenizador y del idioma).

El costo de un modelo de texto en Amazon Bedrock en modalidad bajo demanda es lineal en los tokens: si T_{in} y T_{out} son los tokens de entrada y de salida y $p_{\text{in}}, p_{\text{out}}$ los precios por token, el costo es $p_{\text{in}}T_{\text{in}} + p_{\text{out}}T_{\text{out}}$. Con la regla de $\frac{3}{4}$, una página de 500 palabras son unos $500/0.75 \approx 667$ tokens. Los modelos de imagen suelen cobrarse por imagen y existen modalidades de capacidad reservada, como advierte el documento original.

11. Desbalance de clases

Motivación. En clasificación binaria con una clase positiva rara (enfermedad, fraude) de proporción π , los algoritmos que minimizan el error promedio encuentran rentable ignorarla. El resultado siguiente,

que la guía ilustra con el 99 % de personas sanas, lo hace preciso.

Proposición 11.1 (Paradoja de la exactitud y umbral de Bayes). Sea $\eta(x) = \mathbb{P}(Y = 1 \mid X = x)$ y $\pi = \mathbb{P}(Y = 1)$. (i) El clasificador constante $\hat{y} \equiv 0$ tiene exactitud $1 - \pi$ y sensibilidad (recall) 0. (ii) Si un error sobre la clase 1 cuesta $w_1 > 0$ y uno sobre la clase 0 cuesta $w_0 > 0$, el clasificador que minimiza el costo esperado predice 1 si y solo si $\eta(x) > \frac{w_0}{w_0 + w_1}$. Con $w_0 = w_1$ el umbral es $\frac{1}{2}$.

Demostración. (i) Acierta exactamente cuando $Y = 0$, con probabilidad $1 - \pi$, y nunca predice 1. (ii) Condicionando a $X = x$, predecir 1 tiene costo esperado $w_0(1 - \eta(x))$ (se equivoca si $Y = 0$) y predecir 0 tiene costo $w_1\eta(x)$. Conviene predecir 1 si $w_0(1 - \eta(x)) < w_1\eta(x)$, es decir, $w_0 < (w_0 + w_1)\eta(x)$. Minimizar punto a punto minimiza la esperanza total, porque el costo esperado es la integral de los costos condicionales. $\square$

Si la clase positiva es rara, $\eta(x)$ rara vez supera $\frac{1}{2}$ y el clasificador óptimo para la exactitud casi nunca predice la clase de interés. Las técnicas de mitigación de la guía cambian, de maneras distintas, los pesos efectivos w_0, w_1 o los datos.

11.1. Ponderación y remuestreo

Definición 11.2 (Pesos balanceados). Con K clases de tamaños $n_1, \dots, n_K$ y $n = \sum n_c$, los pesos balanceados son $w_c = \frac{n}{K n_c}$, y el riesgo ponderado es $\hat{R}_w(f) = \frac{1}{n} \sum_i w_{y_i} \ell(f(x_i), y_i)$.

La fórmula es la que usa `class_weight="balanced"` en scikit-learn. Su justificación es que iguala la contribución total de cada clase: la suma de los pesos de la clase c es $n_c \cdot \frac{n}{K n_c} = \frac{n}{K}$, la misma para todas. En el caso binario, el cociente $w_1/w_0 = n_0/n_1$ es el que usa `scale_pos_weight` en XGBoost, y por la Proposición 11.1(ii) el umbral de Bayes pasa de $\frac{1}{2}$ a $\frac{w_0}{w_0 + w_1} = \frac{n_1}{n_0 + n_1} = \hat{\pi}$: se predice la clase rara en cuanto su probabilidad condicional supera su frecuencia marginal.

Proposición 11.3 (Remuestreo y ponderación coinciden en esperanza). (i) Sobremuestreo aleatorio: si cada ejemplo de la clase 1 se incluye M_i veces, con M_i aleatorios de media r independientes de los datos, el riesgo empírico (sin normalizar) tiene esperanza $\sum_{y_i=0} \ell_i + r \sum_{y_i=1} \ell_i$. (ii) Submuestreo aleatorio: si cada ejemplo de la clase 0 se conserva con probabilidad β , independientemente, la esperanza es $\beta \sum_{y_i=0} \ell_i + \sum_{y_i=1} \ell_i$. En ambos casos coincide con un riesgo ponderado con $w_1/w_0 = r$ o $w_1/w_0 = 1/\beta$.

Demostración. Por la Proposición 2.14, un ejemplo incluido M veces contribuye $M\ell_i$. (i) $\mathbb{E}[\sum_{y_i=0} \ell_i + \sum_{y_i=1} M_i \ell_i] = \sum_{y_i=0} \ell_i + r \sum_{y_i=1} \ell_i$ por linealidad. (ii) Con $B_i \sim \text{Bernoulli}(\beta)$, $\mathbb{E}[\sum_{y_i=0} B_i \ell_i] = \beta \sum_{y_i=0} \ell_i$. $\square$

La proposición muestra que las tres técnicas persiguen el mismo cambio de pesos, y sus diferencias están en la varianza y en la información. La ponderación lo logra de forma determinista y sin descartar datos. El sobremuestreo añade aleatoriedad y repite ejemplos, lo que favorece el sobreajuste a esos puntos. El submuestreo descarta en promedio una fracción $1 - \beta$ de la clase mayoritaria: con 0.1 % de fraudes y balance total ($\beta = n_1/n_0 \approx 0.001$) se descarta el 99.9 % de las transacciones legítimas, y la varianza de todo lo estimado sobre esa clase se multiplica por el orden de $1/\beta$. El submuestreo cambia además las probabilidades que aprende el modelo.

Proposición 11.4 (Corrección de probabilidades tras submuestreo). Si la clase 0 se submuestraa con probabilidad β independiente de x , la probabilidad condicional en los datos submuestreados es $\eta_\beta(x) = \frac{\eta(x)}{\eta(x) + \beta(1 - \eta(x))}$, y la original se recupera como $\eta(x) = \frac{\beta \eta_\beta(x)}{1 - \eta_\beta(x) + \beta \eta_\beta(x)}$.

Demostración. Sea S el indicador de que un registro se conserva, con $\mathbb{P}(S = 1 \mid Y = 1, X = x) = 1$ y $\mathbb{P}(S = 1 \mid Y = 0, X = x) = \beta$. Por la regla de Bayes,

$$\eta_\beta(x) = \mathbb{P}(Y = 1 \mid X = x, S = 1) = \frac{1 \cdot \eta(x)}{1 \cdot \eta(x) + \beta(1 - \eta(x))}.$$

Despejando: $\eta_\beta(\eta + \beta - \beta\eta) = \eta$, es decir, $\eta_\beta\beta = \eta(1 - \eta_\beta + \beta\eta_\beta)$, que da la segunda fórmula (el paréntesis es positivo: $1 - \eta_\beta + \beta\eta_\beta = 1 - (1 - \beta)\eta_\beta \geq \beta > 0$ porque $\eta_\beta \leq 1$). $\square$

Un modelo entrenado sobre datos submuestreados sobrestima la probabilidad de la clase rara; si se necesitan probabilidades calibradas (por ejemplo, para fijar un umbral de costo), hay que aplicar la corrección.

11.2. SMOTE

Motivación. El sobremuestreo aleatorio repite puntos exactos, y un modelo flexible puede aislarlos con regiones diminutas alrededor de cada uno. Chawla, Bowyer, Hall y Kegelmeyer (2002) propusieron generar puntos nuevos entre ejemplos minoritarios cercanos, para que la región de decisión de la clase rara se ensanche en lugar de fragmentarse.

Definición 11.5 (SMOTE). Para generar un punto sintético: se elige un ejemplo minoritario x , se elige al azar uno x' entre sus k vecinos más cercanos dentro de la clase minoritaria, se toma $u \sim U(0, 1)$ independiente y se define $z = x + u(x' - x)$.

Proposición 11.6 (Propiedades de SMOTE). (i) z está en el segmento $[x, x']$ y, por tanto, en la envolvente convexa de los ejemplos minoritarios; SMOTE no puede generar puntos fuera de ella. (ii) Si, como modelo simplificado, x y x' fueran independientes con la misma distribución, de media μ y covarianza Σ , entonces $\mathbb{E}z = \mu$ y $\text{Cov } z = \frac{2}{3}\Sigma$.

Demostración. (i) $z = (1 - u)x + ux'$ con $u \in [0, 1]$ es combinación convexa de x y x' , que pertenecen a la envolvente convexa, y esta es cerrada por combinaciones convexas. (ii) $z - \mu = (1 - u)(x - \mu) + u(x' - \mu)$. Por independencia de u, x, x' , la esperanza es $\mathbb{E}[1 - u] \cdot 0 + \mathbb{E}[u] \cdot 0 = 0$, y la covarianza es $\mathbb{E}[(1 - u)^2]\Sigma + \mathbb{E}[u^2]\Sigma + 2\mathbb{E}[u(1 - u)] \text{Cov}(x, x')$, donde el último término es nulo por independencia. Como $\mathbb{E}[u^2] = \int_0^1 t^2 dt = \frac{1}{3}$ y $\mathbb{E}[(1 - u)^2] = \frac{1}{3}$ por simetría, $\text{Cov } z = \frac{2}{3}\Sigma$. $\square$

La parte (i) es a la vez la virtud y el límite de SMOTE: interpola, nunca extrapola. Si la clase minoritaria forma dos grupos separados por una región de la clase mayoritaria y k es grande, algunos segmentos cruzan esa región y los puntos sintéticos caen donde no hay minoritarios reales, creando ruido de etiqueta. La parte (ii) indica que los puntos sintéticos están más concentrados que los reales: en ese modelo simplificado su dispersión es $2/3$ de la original (con vecinos cercanos la contracción es local, pero del mismo tipo). SMOTE solo tiene sentido en características numéricas continuas (interpolar entre dos categorías codificadas en one-hot da vectores que no corresponden a ninguna categoría) y, como cualquier remuestreo, se aplica solo a $\mathcal{D}_{\text{tr}}$ después de dividir: si se aplica antes, un punto sintético construido con un ejemplo de prueba termina en entrenamiento, que es fuga en el sentido de la Definición 1.3.

11.3. Aumento de datos

El aumento de datos que la guía propone para imágenes (volteos, rotaciones, ajustes de color) usa transformaciones que se sabe que no cambian la etiqueta. Por ejemplo, el volteo horizontal es el operador $(FI)(u, v) = I(u, W - 1 - v)$, que es una permutación de los píxeles y cumple $F \circ F = \text{id}$

(porque $W - 1 - (W - 1 - v) = v$). Si G es un conjunto de tales transformaciones que preservan la etiqueta, entrenar con los pares (gx_i, y_i) , $g \in G$, equivale a minimizar $\frac{1}{n|G|} \sum_i \sum_{g \in G} \ell(f(gx_i), y_i)$, el riesgo promediado sobre las transformaciones. Esto incorpora la invariancia al entrenamiento, del mismo modo que el Corolario 9.4 la incorpora a la arquitectura. La hipótesis de invariancia debe verificarse en cada problema: el volteo horizontal preserva “gato”, pero no el dígito “2” ni la lateralidad de una radiografía. El aumento de texto (sinónimos, inserciones) descansa en la hipótesis análoga, más frágil. Como indica la guía, el aumento parte de los datos existentes, mientras que los datos sintéticos se generan sin usar el conjunto original.

11.4. Métricas de sesgo previas al entrenamiento

SageMaker Clarify cuantifica, antes de entrenar, cuán representado está cada grupo. Sea una *faceta* una característica que define dos grupos: a (el que se sospecha favorecido) y d (el desfavorecido), con n_a y n_d registros, de los cuales $n_a^{(1)}$ y $n_d^{(1)}$ tienen la etiqueta positiva.

Definición 11.7 (CI y DPL). El *desbalance de clases* de la faceta es $CI = \frac{n_a - n_d}{n_a + n_d}$ y la *diferencia en proporciones de etiquetas* es $DPL = q_a - q_d$, con $q_a = n_a^{(1)}/n_a$ y $q_d = n_d^{(1)}/n_d$.

Proposición 11.8 (Rangos). $CI \in [-1, 1]$, con $CI = 0$ si y solo si $n_a = n_d$ y $CI = \pm 1$ si y solo si uno de los grupos está vacío. Para etiquetas binarias, $DPL \in [-1, 1]$, con $DPL = 0$ si y solo si ambos grupos tienen la misma proporción de positivos.

Demostración. Como $n_a, n_d \geq 0$ y $n_a + n_d > 0$, $|n_a - n_d| \leq n_a + n_d$, con igualdad si y solo si $n_a = 0$ o $n_d = 0$; el cociente vale 0 si y solo si $n_a = n_d$. Para DPL, $q_a, q_d \in [0, 1]$ porque $0 \leq n^{(1)} \leq n$, y la diferencia de dos números de $[0, 1]$ está en $[-1, 1]$. $\square$

En el ejemplo de la guía, con 10^6 transacciones, $n_a = 999\,000$ legítimas y $n_d = 1000$ fraudulentas, $CI = 998\,000/10^6 = 0.998$. Como advierte el documento original, usar la etiqueta misma como faceta hace que CI mida solo el desbalance de la etiqueta; el uso previsto es una faceta demográfica, y entonces DPL es la diferencia de las tasas de resultado favorable entre grupos, el numerador del estadístico de la prueba de dos proporciones. Ambas métricas se calculan con conteos, sin necesidad del servicio.

12. División de datos y fuga

La Definición 1.3 fija el principio: toda transformación ajustada se ajusta con $\mathcal{D}_{tr}$ y se aplica sin cambios a validación y prueba. Esta sección estudia cómo construir la partición.

Tamaño del conjunto de prueba. Si la exactitud verdadera es a y el conjunto de prueba tiene n_{te} registros independientes, la exactitud medida es una proporción binomial con desviación estándar $\sqrt{a(1-a)/n_{te}}$ (la varianza de una media de n_{te} variables Bernoulli(a)). Con $a = 0.9$ y $n_{te} = 1000$ es 0.0095: diferencias de un punto porcentual entre modelos están en el nivel del ruido. Las proporciones de la guía (60–80 % para entrenamiento, 10–20 % para validación y prueba) son un compromiso entre esta varianza y la cantidad de datos para aprender.

Proposición 12.1 (Clases raras en una división aleatoria). Si un conjunto de N registros con K positivos se divide eligiendo al azar n registros para prueba, el número de positivos en prueba es hipergeométrico, con media nK/N y

$$\mathbb{P}(\text{ningún positivo en prueba}) = \frac{\binom{N-K}{n}}{\binom{N}{n}} = \prod_{i=0}^{n-1} \frac{N-K-i}{N-i} \leq \left(1 - \frac{n}{N}\right)^K.$$

Demostración. Todos los subconjuntos de tamaño n son equiprobables, y los que no contienen positivos son los $\binom{N-K}{n}$ subconjuntos de los $N-K$ negativos. Escribiendo los binomiales con factoriales,

$$\frac{\binom{N-K}{n}}{\binom{N}{n}} = \frac{(N-K)!(N-n)!}{(N-K-n)!N!} = \frac{(N-n)(N-n-1)\cdots(N-n-K+1)}{N(N-1)\cdots(N-K+1)},$$

ya que $(N-n)!/(N-n-K)!$ y $N!/(N-K)!$ son productos de K factores consecutivos descendentes. Cada factor cumple $\frac{N-n-i}{N-i} = 1 - \frac{n}{N-i} \leq 1 - \frac{n}{N}$. La media es K veces la probabilidad n/N de que un positivo dado caiga en prueba. $\square$

Con $N = 10\,000$, $K = 10$ fraudes (0.1 %) y $n = 1000$ (10 % para prueba), el número esperado de fraudes en prueba es 1 y la probabilidad de no tener ninguno es ≈ 0.349 (la cota da $0.9^{10} \approx 0.349$). Una de cada tres divisiones aleatorias dejaría el conjunto de prueba sin la clase que se quiere detectar. La nota de precisión del documento original (“la división aleatoria no asegura proporciones”) queda así cuantificada.

División estratificada. Se divide cada clase por separado con la misma fracción f : la clase c aporta $\lfloor fn_c \rfloor$ o $\lceil fn_c \rceil$ registros a prueba, de modo que la proporción de cada clase en prueba difiere de la global solo por redondeo (menos de un registro por clase). Elimina la variabilidad de la Proposición 12.1.

División por clave. Si varios registros comparten una clave (un cliente, un paciente), están correlacionados. Repartirlos entre entrenamiento y prueba produce el efecto de la Proposición 2.14 de forma atenuada: el modelo se evalúa en casi duplicados de lo que vio. Asignar claves completas a una sola partición mide el desempeño en claves nuevas, que es lo que ocurrirá en producción.

División ordenada. En series de tiempo, entrenar con el pasado y evaluar con el futuro es la única partición compatible con la Definición 8.1; una partición aleatoria permite que el modelo interpole entre observaciones vecinas en el tiempo, lo que no podrá hacer al pronosticar.

Orden de las operaciones. Con lo anterior, el orden correcto es: deduplicar $\rightarrow$ dividir (estratificada, por clave u ordenada según el caso) $\rightarrow$ ajustar con $\mathcal{D}_{\text{tr}}$ imputación, límites de atípicos, transformaciones, escaladores, codificadores, selección y PCA $\rightarrow$ remuestrear o ponderar solo $\mathcal{D}_{\text{tr}}$ $\rightarrow$ aplicar las transformaciones ya ajustadas a validación y prueba. Un **Pipeline** de scikit-learn evaluado con validación cruzada ejecuta este orden dentro de cada pliegue.

13. Servicios de AWS donde se aplican las técnicas

Esta sección sigue el reparto de servicios del documento original. Advertencias vigentes según ese documento (verificadas por él el 23 de septiembre de 2026): Amazon SageMaker se llama ahora Amazon SageMaker AI; SageMaker Data Wrangler está integrado en SageMaker Canvas; SageMaker Ground Truth y SageMaker Clarify ya no admiten clientes nuevos (los existentes pueden seguir usándolos); Amazon Mechanical Turk cierra el 30 de septiembre de 2026. Los nombres de transformaciones son los de la documentación de AWS y conviene confirmarlos en la versión vigente.

Herramientas transversales. **SageMaker Data Wrangler** (dentro de Canvas) es la herramienta visual de bajo código para casi todas las técnicas de este texto y exporta el flujo a S3, a un pipeline de SageMaker, a Feature Store o a un script. **AWS Glue DataBrew** es la alternativa visual sin código de la familia Glue, con recetas reutilizables que se ejecutan como trabajos serverless. Los **notebooks de SageMaker** permiten usar scikit-learn, pandas y `category_encoders` con el código de la guía (`SimpleImputer`, `StandardScaler`, `PowerTransformer`, `OneHotEncoder`, `FeatureHasher`),

y los **trabajos de AWS Glue** (PySpark) ejecutan la misma lógica de forma repetible sobre el volumen completo.

Técnica (sección)	Servicios de AWS
Valores faltantes (2.1)	Data Wrangler: <i>Handle missing</i> (<i>Impute missing</i> con media, mediana o moda; <i>Fill missing</i> ; <i>Add indicator for missing</i> ; <i>Drop missing</i>). Glue DataBrew: transformaciones integradas de relleno. Notebooks: SimpleImputer .
Atípicos (2.2)	Data Wrangler: <i>Handle outliers</i> (desviación estándar, desviación estándar robusta, cuantiles, mínimo-máximo; recortar, eliminar o invalidar). Glue DataBrew: marcar, eliminar, reemplazar o reescalar atípicos por puntuación Z o IQR. Notebooks: pandas y SciPy.
Deduplicación (2.3)	Glue DataBrew (opción que la guía recomienda por simplicidad).
Selección y PCA (3)	Data Wrangler: <i>Dimensionality Reduction</i> (PCA por número de componentes o umbral de varianza, con opción de centrar y escalar). Algoritmo integrado PCA de SageMaker AI. Notebooks: información mutua y χ^2 de scikit-learn.
Escalado (4)	Data Wrangler: <i>Process numeric</i> (<i>Standard Scaler</i> , <i>Robust Scaler</i> , <i>Min Max Scaler</i> , <i>Max Absolute Scaler</i>). Glue DataBrew: SCALE (MIN_MAX , SCALE_BETWEEN , MEAN_NORMALIZATION , Z_SCORE). Notebooks y Glue jobs.
Transformaciones no lineales (5)	Notebooks o trabajos de procesamiento de SageMaker: PowerTransformer (Box-Cox, Yeo-Johnson), np.log1p . Data Wrangler: <i>Custom formula</i> con funciones de Spark SQL. Glue DataBrew: transformaciones de sesgo.
Discretización (6)	Glue DataBrew: BUCKETIZATION . Notebooks: KBinsDiscretizer .
Catóricas (7)	Data Wrangler: <i>Encode categorical</i> (<i>Ordinal encode</i> , <i>One-hot encode</i> , <i>Similarity encode</i>). Glue DataBrew: ONE_HOT_ENCODING , CATEGORICAL_MAPPING . Notebooks: OrdinalEncoder , OneHotEncoder , BinaryEncoder , FeatureHasher .
Series de tiempo (8)	Data Wrangler, transformaciones de series de tiempo: <i>Featurize datetime</i> (modo ordinal o cíclico), <i>One-hot encode</i> , <i>Lag features</i> , <i>Rolling window features</i> , <i>Extract features</i> , además de remuestreo e imputación temporal. Feature Store: consultas <i>point-in-time</i> .
Imágenes (9)	SageMaker JumpStart: modelos de visión preentrenados (CNN) para extraer embeddings. Amazon Rekognition: etiquetas, objetos, texto, rostros y cuadros delimitadores por API. Data Wrangler: normalización y PCA. Feature Store: almacenamiento y reutilización.
Texto (10)	Amazon Comprehend: entidades, frases clave, sentimiento, idioma. Amazon Textract: OCR, formularios y tablas. Algoritmos integrados de SageMaker AI: BlazingText (Word2Vec) y LDA (tópicos). Data Wrangler: <i>Featurize text</i> (<i>Character statistics</i> , <i>Vectorize</i> con TF-IDF). Glue DataBrew: TOKENIZATION . Amazon Bedrock: modelos fundacionales con tokenización por subpalabras y cobro por tokens.
Etiquetado	SageMaker Ground Truth (sin clientes nuevos).
Desbalance (11)	Data Wrangler: <i>Balance data</i> (<i>Random oversampling</i> , <i>Random undersampling</i> , SMOTE). Ponderación dentro de los algoritmos (scale_pos_weight en XGBoost). SageMaker Clarify: métricas CI y DPL previas al entrenamiento (sin clientes nuevos; se calculan igual con pandas).
División (12)	Data Wrangler: <i>Split data</i> (<i>Randomized</i> , <i>Ordered</i> , <i>Stratified</i> , <i>Split by key</i>), con semilla reproducible.
Almacenar y servir características	SageMaker Feature Store: almacén <i>online</i> para inferencia en tiempo real y <i>offline</i> en S3 para entrenamiento, con consultas <i>point-in-time</i> que evitan la fuga (Definición 8.1) y el <i>training-serving skew</i> .
Datos de origen	Amazon S3 como lago de datos y fuente única de verdad; AWS Glue Data Catalog y <i>crawlers</i> ; Amazon Athena para consultas; AWS Lake Formation para permisos por columna, fila y celda.

El hilo común con el desarrollo matemático es la Definición 1.2: cada herramienta separa el ajuste

de la aplicación de las transformaciones. Data Wrangler y DataBrew lo hacen al guardar el flujo o la receta y reaplicarla a datos nuevos; Feature Store lo hace al calcular cada característica una sola vez y servir el mismo valor al entrenamiento y a la inferencia. Es esa separación la que impide la fuga de datos y el *training-serving skew*.

Referencias

- [1] G. E. P. Box y D. R. Cox, An analysis of transformations, *J. Roy. Statist. Soc. B* **26** (1964), 211–252.
- [2] N. V. Chawla, K. W. Bowyer, L. O. Hall y W. P. Kegelmeyer, SMOTE: Synthetic minority over-sampling technique, *J. Artificial Intelligence Res.* **16** (2002), 321–357. arXiv:1106.1813.
- [3] M. Kuhn y K. Johnson, *Feature Engineering and Selection: A Practical Approach for Predictive Models*, CRC Press, 2019. Versión en línea: <https://feat.engineering/>.
- [4] O. Levy e Y. Goldberg, Neural word embedding as implicit matrix factorization, *Advances in Neural Information Processing Systems* **27** (2014).
- [5] T. Mikolov, I. Sutskever, K. Chen, G. Corrado y J. Dean, Distributed representations of words and phrases and their compositionality, *Advances in Neural Information Processing Systems* **26** (2013).
- [6] J. Pennington, R. Socher y C. D. Manning, GloVe: Global vectors for word representation, *Proc. EMNLP* (2014).
- [7] D. B. Rubin, Inference and missing data, *Biometrika* **63** (1976), 581–592.
- [8] R. Sennrich, B. Haddow y A. Birch, Neural machine translation of rare words with subword units, *Proc. ACL* (2016).
- [9] R. E. Shiffler, Maximum Z scores and outliers, *Amer. Statist.* **42** (1988), 79–80.
- [10] J. W. Tukey, *Exploratory Data Analysis*, Addison-Wesley, 1977.
- [11] K. Weinberger, A. Dasgupta, J. Langford, A. Smola y J. Attenberg, Feature hashing for large scale multitask learning, *Proc. ICML* (2009). arXiv:0902.2206.
- [12] I.-K. Yeo y R. A. Johnson, A new family of power transformations to improve normality or symmetry, *Biometrika* **87** (2000), 954–959.
- [13] Amazon Web Services, *Amazon SageMaker AI Developer Guide* (transformaciones de Data Wrangler en Canvas, BlazingText) y *AWS Glue DataBrew Developer Guide* (acciones de receta), consultadas en septiembre de 2026.